

Влияние информации на рыночные колебания цен (на основе информации о санкциях)

Горохов Андрей, группа М05-2086.

Программный код.

В рамках данного раздела проекта будут проверены модели, которые были сформулированы в предыдущем разделе.

Подготовительный этап - подготовка данных.

В рамках данного пункта будут сделаны необходимые подготовительные процессы для проведения исследования и подготовки к моделированию и проверки гипотез.

Первым этапом будет загрузка библиотек Python.

```
In [1]: import pandas as pd
import numpy as np
import warnings
## Построение моделей
from sklearn import linear_model
from scipy import stats
import statsmodels
import statsmodels.api as sm
import statsmodels.formula.api as smf
import statsmodels.stats.api as sms
from statsmodels.compat import lzip
## Визуализация
import seaborn as sns
import matplotlib.pyplot as plt
```

Рис. 1. Загрузка библиотек в Python

После импорта необходимых библиотек, загрузим данные в Jupiter. Также предварительно были изменены названия столбцов в более краткой форме.

Также в изначальных данных информация о ВВП Сирии за последние три года была недоступна в силу политических обстоятельств в стране. Заполним эти данные в соответствии с информацией, которые дает Международный валютный фонд о росте ВВП в стране. Так МВФ говорит, что ВВП в Сирии в среднем растет на 2% в год.

```
In [41]: df = pd.read_excel("C:/Users/Andrew/DataProject.xlsx")
```

```
In [3]: df.head()
```

```
Out[3]:
```

	Year	IranGDP	RussiaGDP	VenGDP	SyrGDP	Oil_price	EU_gas_price	US_gas_price	Barl_Price	Trade_sanc	War_sanc	Warcoop_sanc	Fin_sanc	Tour_sanc
0	1980	95.85	940.4	69.84	13.06	37.89	137.6	51.80	441.36	33	16	15	43	
1	1981	101.48	906.3	78.37	16.76	36.68	150.0	64.65	395.44	35	15	14	46	
2	1982	125.80	959.9	80.00	17.53	33.42	145.1	80.36	338.52	41	20	12	53	
3	1983	156.93	993.1	79.67	18.67	29.55	132.0	84.51	354.40	37	18	11	50	
4	1984	161.72	938.3	57.83	19.20	28.28	122.6	86.54	355.00	35	18	9	46	

Рис. 2. Загруженные данные

Данные были успешно загружены. Далее рассмотрим модели, которые были описаны в предыдущем разделе. Всего их 12.

1. Влияние различных видов санкций на цены на пшеницу.
2. Влияние различных видов санкций на цены на природный газ в Европейском союзе.
3. Влияние различных видов санкций на цены на природный газ в США.
4. Влияние различных видов санкций на цены на нефть марки Brent.
5. Влияние различных видов санкций на ВВП Ирана.
6. Влияние различных видов санкций на ВВП Сирии.
7. Влияние различных видов санкций на ВВП Венесуэлы.
8. Влияние различных видов санкций на ВВП Российской Федерации.
9. Комплексное влияние цен на биржевые товары на ВВП Сирии.
10. Комплексное влияние цен на биржевые товары на ВВП Ирана.
11. Комплексное влияние цен на биржевые товары на ВВП Венесуэлы.
12. Комплексное влияние цен на биржевые товары на ВВП Российской Федерации.

Для каждой из моделей создадим необходимый датасет, который будет содержать только необходимую информацию для анализа.

```
In [4]: df1 = df[["Barl_Price", "Trade_sanc", "War_sanc", "Warcoop_sanc", "Fin_sanc", "Tour_sanc", "Other_sanc"]]
df2 = df[["EU_gas_price", "Trade_sanc", "War_sanc", "Warcoop_sanc", "Fin_sanc", "Tour_sanc", "Other_sanc"]]
df3 = df[["US_gas_price", "Trade_sanc", "War_sanc", "Warcoop_sanc", "Fin_sanc", "Tour_sanc", "Other_sanc"]]
df4 = df[["Oil_price", "Trade_sanc", "War_sanc", "Warcoop_sanc", "Fin_sanc", "Tour_sanc", "Other_sanc"]]
df5 = df[["IranGDP", "Trade_sanc", "War_sanc", "Warcoop_sanc", "Fin_sanc", "Tour_sanc", "Other_sanc"]]
df6 = df[["SyrGDP", "Trade_sanc", "War_sanc", "Warcoop_sanc", "Fin_sanc", "Tour_sanc", "Other_sanc"]]
df7 = df[["VenGDP", "Trade_sanc", "War_sanc", "Warcoop_sanc", "Fin_sanc", "Tour_sanc", "Other_sanc"]]
df8 = df[["RussiaGDP", "Trade_sanc", "War_sanc", "Warcoop_sanc", "Fin_sanc", "Tour_sanc", "Other_sanc"]]
df9 = df[["IranGDP", "Oil_price", "EU_gas_price", "US_gas_price", "Barl_Price"]]
df10 = df[["SyrGDP", "Oil_price", "EU_gas_price", "US_gas_price", "Barl_Price"]]
df11 = df[["VenGDP", "Oil_price", "EU_gas_price", "US_gas_price", "Barl_Price"]]
df12 = df[["RussiaGDP", "Oil_price", "EU_gas_price", "US_gas_price", "Barl_Price"]]
```

Рис. 3. Загрузка моделей в отдельные таблицы

Для первичного анализа, построим графики типа pairplot, определим первичный вид корреляционной связи и распределение признаков.

```
In [5]: sns.pairplot(df1)
Out[5]: <seaborn.axisgrid.PairGrid at 0x254ae454190>
```

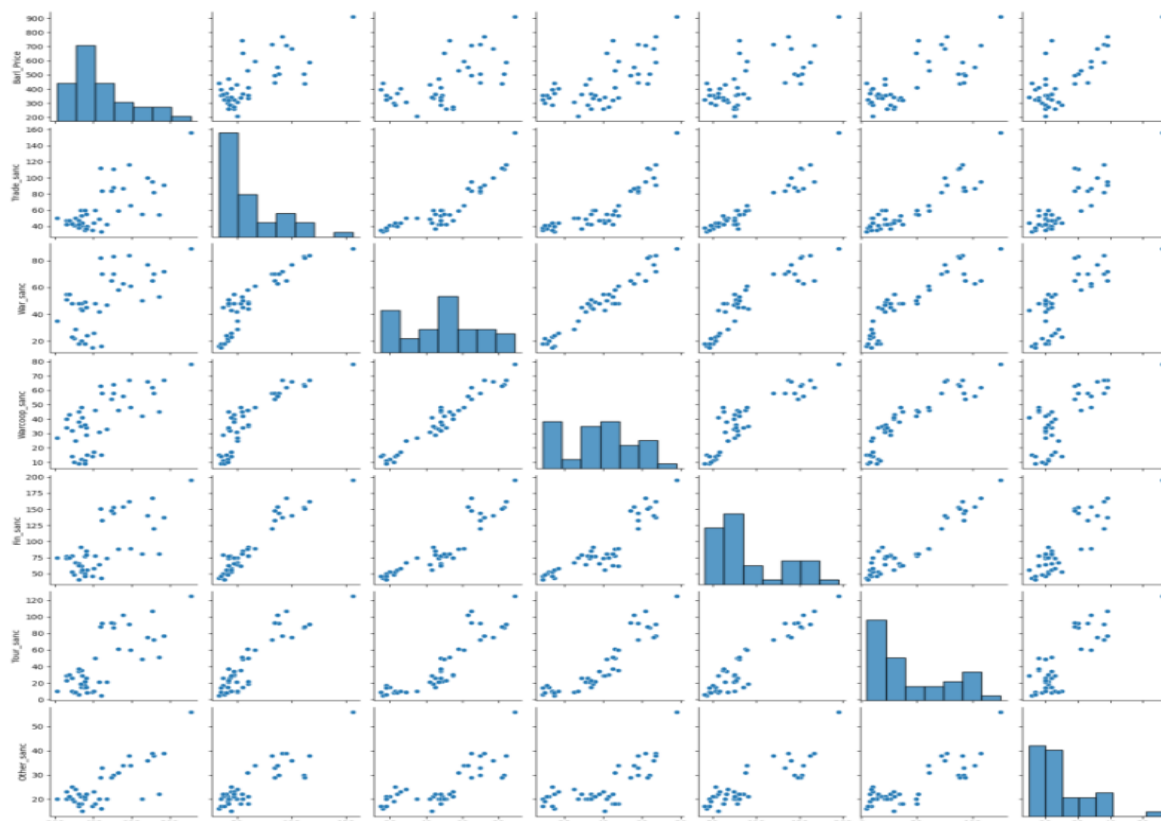


Рис. 4. Pairplot первой модели

```
In [23]: sns.pairplot(df2)
Out[23]: <seaborn.axisgrid.PairGrid at 0x1ba331d1dee>
```




Рис. 5. Pairplot второй модели

```
In [24]: sns.pairplot(df3)
Out[24]: <seaborn.axisgrid.PairGrid at 0x1ba37e66d60>
```




Рис. 6. Pairplot третьей модели

```
In [25]: sns.pairplot(df4)
Out[25]: <seaborn.axisgrid.PairGrid at 0x1ba3a63ac40>
```

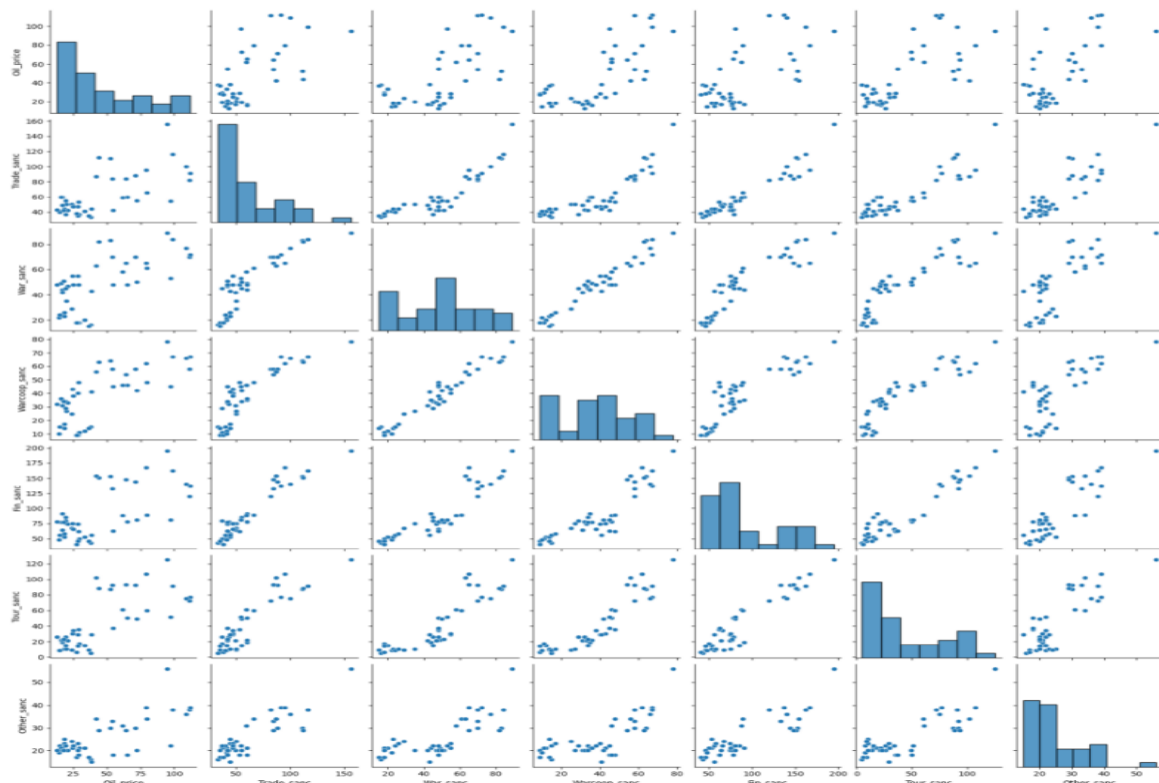


Рис. 7. Pairplot четвертой модели

```
In [26]: sns.pairplot(df5)
Out[26]: <seaborn.axisgrid.PairGrid at 0x1ba3b83fb80>
```




Рис. 8. Pairplot пятой модели

```
In [27]: sns.pairplot(df6)
Out[27]: <seaborn.axisgrid.PairGrid at 0x1ba42c3bdc0>
```

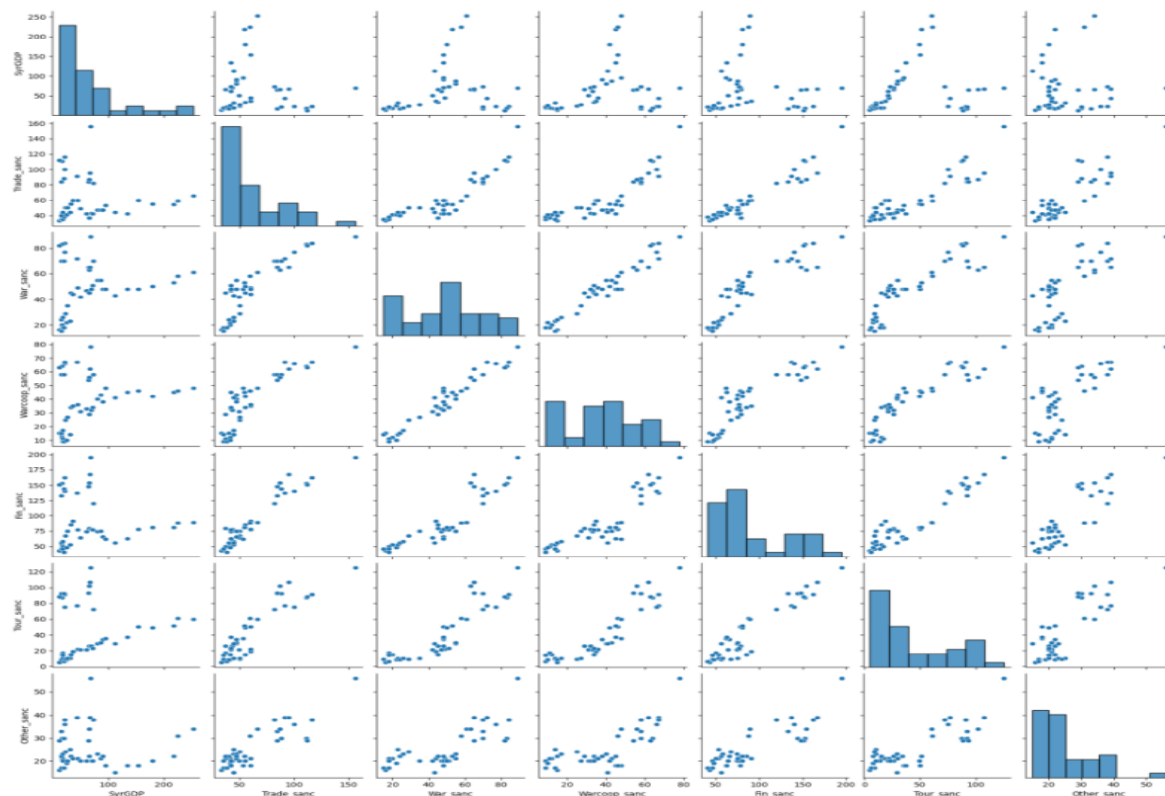


Рис. 9. Pairplot шестой модели

```
In [28]: sns.pairplot(df7)
Out[28]: <seaborn.axisgrid.PairGrid at 0x1ba41951ca0>
```




Рис. 10. Pairplot седьмой модели

```
In [29]: sns.pairplot(df8)
Out[29]: <seaborn.axisgrid.PairGrid at 0x1ba4562a310>
```




Рис. 11. Pairplot восьмой модели




Рис. 12. Pairplot девятой модели




Рис. 13. Pairplot десятой модели

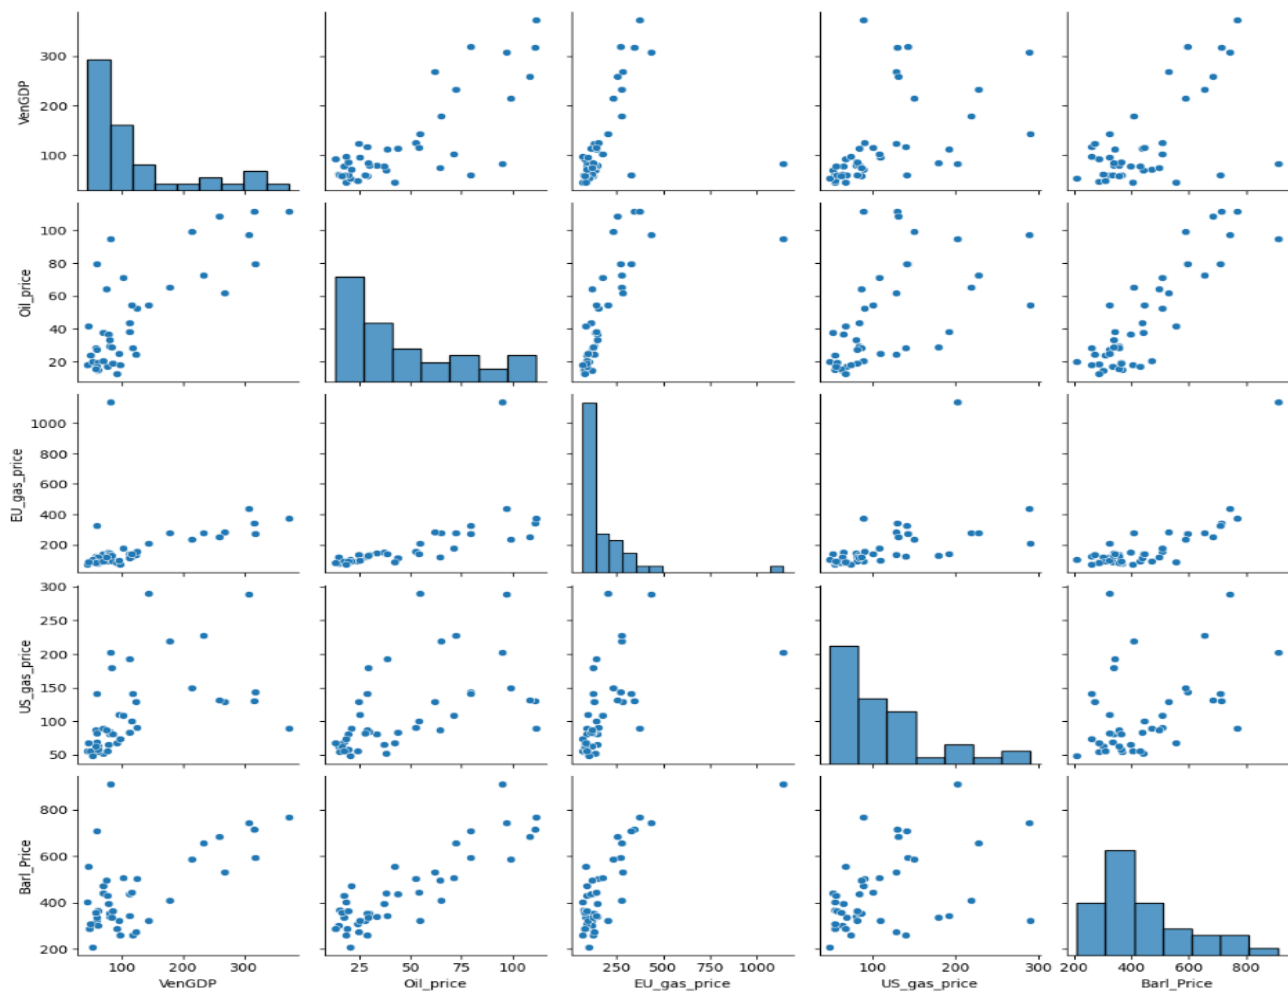


Рис. 14. Pairplot одиннадцатой модели

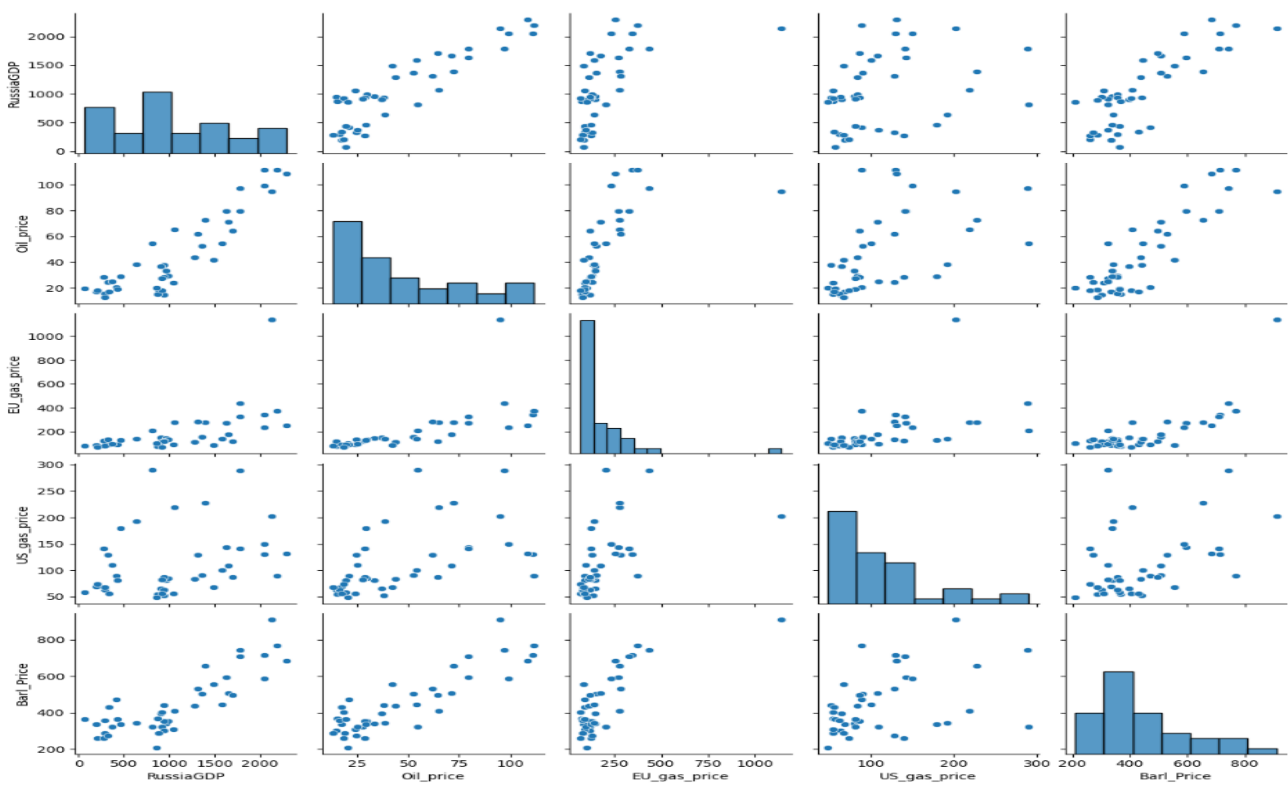


Рис. 15. Pairplot двенадцатой модели

После первичной оценки взаимосвязей исследуемых признаков, можно сделать краткие выводы о виде взаимосвязи исследуемой переменной с каждым из регрессоров по отдельности.

В каждой из моделей рассматриваемые признаки отличны от нормального распределения. Большая часть признаков распределены в соответствии с распределением Хи-квадрат или Лог-нормальным распределением.

Стоит отметить, что несмотря на то, что большинство регрессоров имеют линейную взаимосвязь с объясняемыми переменными, некоторые регрессоры имеют нелинейные связи (как, например, взаимосвязь ВВП России и финансовыми санкциями). Поэтому далее будут проверяться различные виды регрессии.

Построение моделей - построение моделей множественной регрессии без фиктивных переменных.

Сначала рассмотрим линейные модели множественной регрессии и их основные статистики. Сразу же стоит отобрать значимые признаки в модели.

Рассмотрим первую модель.

```
In [17]: res1 = smf.ols("Barl_Price ~ Trade_sanc + War_sanc + Warcoop_sanc + Fin_sanc + Tour_sanc + Other_sanc", data=df1).fit()
res1.summary()
```

Out[17]:

OLS Regression Results

Dep. Variable:	Barl_Price	R-squared:	0.696			
Model:	OLS	Adj. R-squared:	0.645			
Method:	Least Squares	F-statistic:	13.73			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	4.75e-08			
Time:	13:23:50	Log-Likelihood:	-253.87			
No. Observations:	43	AIC:	521.7			
Df Residuals:	36	BIC:	534.1			
Df Model:	6					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	172.0160	72.470	2.374	0.023	25.040	318.992
Trade_sanc	0.4161	1.962	0.212	0.833	-3.563	4.395
War_sanc	-5.7107	3.424	-1.668	0.104	-12.655	1.234
Warcoop_sanc	6.9681	3.949	1.765	0.086	-1.040	14.976
Fin_sanc	-1.9130	1.675	-1.142	0.261	-5.309	1.483
Tour_sanc	2.3115	1.609	1.436	0.160	-0.952	5.575
Other_sanc	12.8558	3.982	3.228	0.003	4.779	20.932
Omnibus:	13.281	Durbin-Watson:	1.056			
Prob(Omnibus):	0.001	Jarque-Bera (JB):	14.814			
Skew:	1.079	Prob(JB):	0.000607			
Kurtosis:	4.900	Cond. No.	733.			

Рис. 16. Первичная оценка модели

Как видно из результатов, многие признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [18]: res1 = smf.ols("Barl_Price ~ War_sanc + Warcoop_sanc + Other_sanc", data=df1).fit()
res1.summary()
```

Out[18]: OLS Regression Results

Dep. Variable:	Barl_Price	R-squared:	0.677			
Model:	OLS	Adj. R-squared:	0.652			
Method:	Least Squares	F-statistic:	27.19			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	1.17e-09			
Time:	13:23:51	Log-Likelihood:	-255.20			
No. Observations:	43	AIC:	518.4			
Df Residuals:	39	BIC:	525.4			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	112.7724	50.686	2.225	0.032	10.251	215.294
War_sanc	-7.4952	3.141	-2.387	0.022	-13.848	-1.143
Warcoop_sanc	9.4695	3.412	2.775	0.008	2.568	16.371
Other_sanc	12.9268	2.681	4.822	0.000	7.504	18.350
Omnibus:	17.352	Durbin-Watson:	0.941			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	24.308			
Skew:	1.228	Prob(JB):	5.27e-06			
Kurtosis:	5.746	Cond. No.	252.			

Рис. 17. Итоговая оценка модели

Из данной модели получается, что на цену на пшеницу влияют только пакеты санкций, направленные на противодействие военному сотрудничеству и другие санкции. Объяснением такого результата может быть то, что пшеница является важным товаром, от которого зависит здоровье людей. Поэтому санкции в отношении пшеницы зачастую не применяются.

Военные же санкции вводятся в отношении стран тогда, когда имеет место вооруженные конфликты, которое только увеличивают необходимость стран поддерживать продовольственную безопасность на высоком уровне, что приводит к росту цен на такую продукцию.

Рассмотрим вторую модель.

```
In [19]: res2 = smf.ols("EU_gas_price ~ Trade_sanc + War_sanc + Warcoop_sanc + Fin_sanc + Tour_sanc + Other_sanc", data=df2).fit()
res2.summary()
```

Out[19]: OLS Regression Results

Dep. Variable:	EU_gas_price	R-squared:	0.672			
Model:	OLS	Adj. R-squared:	0.617			
Method:	Least Squares	F-statistic:	12.29			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	1.75e-07			
Time:	13:23:51	Log-Likelihood:	-258.73			
No. Observations:	43	AIC:	531.5			
Df Residuals:	36	BIC:	543.8			
Df Model:	6					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	-113.8965	81.154	-1.403	0.169	-278.485	50.692
Trade_sanc	5.7622	2.197	2.623	0.013	1.306	10.218
War_sanc	-6.2977	3.834	-1.642	0.109	-14.074	1.479
Warcoop_sanc	8.2144	4.422	1.858	0.071	-0.753	17.182
Fin_sanc	-6.1292	1.875	-3.268	0.002	-9.933	-2.326
Tour_sanc	1.4792	1.802	0.821	0.417	-2.176	5.134
Other_sanc	16.4979	4.460	3.699	0.001	7.453	25.542
Omnibus:	18.804	Durbin-Watson:	0.968			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	27.109			
Skew:	1.325	Prob(JB):	1.30e-06			
Kurtosis:	5.848	Cond. No.	733.			

Рис. 18. Первичная оценка модели

Как видно из результатов, многие признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [20]: res2 = smf.ols("EU_gas_price ~ Trade_sanc + War_sanc + Warcoop_sanc + Fin_sanc + Other_sanc", data=df2).fit()
res2.summary()
```

Out[20]: OLS Regression Results

Dep. Variable:	EU_gas_price	R-squared:	0.666
Model:	OLS	Adj. R-squared:	0.621
Method:	Least Squares	F-statistic:	14.74
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	5.82e-08
Time:	13:23:51	Log-Likelihood:	-259.13
No. Observations:	43	AIC:	530.3
Df Residuals:	37	BIC:	540.8
Df Model:	5		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-157.3824	61.204	-2.571	0.014	-281.393	-33.372
Trade_sanc	5.5568	2.173	2.557	0.015	1.154	9.960
War_sanc	-7.1611	3.671	-1.951	0.059	-14.599	0.277
Warcoop_sanc	9.9257	3.882	2.557	0.015	2.060	17.792
Fin_sanc	-5.2735	1.552	-3.398	0.002	-8.418	-2.129
Other_sanc	17.2247	4.351	3.958	0.000	8.408	26.042

Omnibus:	18.601	Durbin-Watson:	0.917
Prob(Omnibus):	0.000	Jarque-Bera (JB):	26.189
Skew:	1.329	Prob(JB):	2.06e-06
Kurtosis:	5.748	Cond. No.	519.

Рис. 19. Итоговая оценка модели

Таким образом, при удалении туристических санкций, данная модель становится значимой. Даже несмотря на то военные санкции немного превышают р-значение. Таким образом, цены на газ в ЕС зависят почти от всех санкций.

Рассмотрим третью модель.

```
In [21]: res3 = smf.ols("US_gas_price ~ Trade_sanc + War_sanc + Warcoop_sanc + Fin_sanc + Tour_sanc + Other_sanc", data=df3).fit()
res3.summary()
```

Out[21]: OLS Regression Results

Dep. Variable:	US_gas_price	R-squared:	0.631
Model:	OLS	Adj. R-squared:	0.570
Method:	Least Squares	F-statistic:	10.27
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	1.29e-06
Time:	13:23:51	Log-Likelihood:	-216.44
No. Observations:	43	AIC:	446.9
Df Residuals:	36	BIC:	459.2
Df Model:	6		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	156.8411	30.350	5.168	0.000	95.289	218.393
Trade_sanc	0.8511	0.822	1.036	0.307	-0.815	2.517
War_sanc	-1.5757	1.434	-1.099	0.279	-4.484	1.333
Warcoop_sanc	4.8917	1.654	2.958	0.005	1.538	8.245
Fin_sanc	-3.0844	0.701	-4.398	0.000	-4.507	-1.662
Tour_sanc	2.0797	0.674	3.086	0.004	0.713	3.447
Other_sanc	-0.9607	1.668	-0.576	0.568	-4.343	2.422

Omnibus:	8.152	Durbin-Watson:	1.367
Prob(Omnibus):	0.017	Jarque-Bera (JB):	7.038
Skew:	0.864	Prob(JB):	0.0296
Kurtosis:	3.971	Cond. No.	733.

Рис. 20. Первичная оценка модели

Как видно из результатов, многие признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [22]: res3 = smf.ols("US_gas_price ~ Warcoop_sanc + Fin_sanc + Tour_sanc ", data=df3).fit()
res3.summary()
```

Out[22]: OLS Regression Results

Dep. Variable:	US_gas_price	R-squared:	0.607
Model:	OLS	Adj. R-squared:	0.576
Method:	Least Squares	F-statistic:	20.04
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	5.07e-08
Time:	13:23:51	Log-Likelihood:	-217.83
No. Observations:	43	AIC:	443.7
Df Residuals:	39	BIC:	450.7
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	144.3804	23.612	6.115	0.000	96.620	192.141
Warcoop_sanc	3.5289	0.801	4.407	0.000	1.909	5.148
Fin_sanc	-2.9473	0.478	-6.167	0.000	-3.914	-1.981
Tour_sanc	2.1925	0.629	3.487	0.001	0.921	3.464

Omnibus:	8.373	Durbin-Watson:	1.243
Prob(Omnibus):	0.015	Jarque-Bera (JB):	7.283
Skew:	0.903	Prob(JB):	0.0262
Kurtosis:	3.895	Cond. No.	462.

Рис. 21. Итоговая оценка модели

Цены на газ в США зависят от санкции в отношении военного сотрудничества (так как газ является одним из видов топлива, которое используется в военной сфере), финансовых санкций и туристических санкций.

Туристические санкции в данной модели, скорее всего, влияют на то, что такие санкции в США вводятся путем ограничения путешествий основным управляющим компаний, которые вносят большой вклад в ВВП стран, в отношении которых вводятся санкции.

Рассмотрим четвертую модель.

```
In [23]: res4 = smf.ols("Oil_price ~ Trade_sanc + War_sanc + Warcoop_sanc + Fin_sanc + Tour_sanc + Other_sanc", data=df4).fit()
res4.summary()
```

Out[23]: OLS Regression Results

Dep. Variable:	Oil_price	R-squared:	0.708
Model:	OLS	Adj. R-squared:	0.660
Method:	Least Squares	F-statistic:	14.57
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	2.33e-08
Time:	13:23:51	Log-Likelihood:	-180.97
No. Observations:	43	AIC:	375.9
Df Residuals:	36	BIC:	388.3
Df Model:	6		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	3.8009	13.303	0.286	0.777	-23.179	30.781
Trade_sanc	0.0741	0.360	0.206	0.838	-0.656	0.804
War_sanc	-1.0406	0.629	-1.656	0.107	-2.315	0.234
Warcoop_sanc	1.8372	0.725	2.535	0.016	0.367	3.307
Fin_sanc	-0.6264	0.307	-2.038	0.049	-1.250	-0.003
Tour_sanc	0.5599	0.295	1.895	0.066	-0.039	1.159
Other_sanc	1.9168	0.731	2.622	0.013	0.434	3.399

Omnibus:	1.893	Durbin-Watson:	0.918
Prob(Omnibus):	0.388	Jarque-Bera (JB):	1.218
Skew:	0.404	Prob(JB):	0.544
Kurtosis:	3.162	Cond. No.	733.

Рис. 22. Первичная оценка модели

Как видно из результатов, многие признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [24]: res4 = smf.ols("Oil_price ~ Warcoop_sanc + Fin_sanc + Tour_sanc + Other_sanc", data=df4).fit()
res4.summary()
```

Out[24]: OLS Regression Results

Dep. Variable:	Oil_price	R-squared:	0.685			
Model:	OLS	Adj. R-squared:	0.652			
Method:	Least Squares	F-statistic:	20.70			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	4.02e-09			
Time:	13:23:51	Log-Likelihood:	-182.59			
No. Observations:	43	AIC:	375.2			
Df Residuals:	38	BIC:	384.0			
Df Model:	4					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	0.3173	13.120	0.024	0.981	-26.243	26.878
Warcoop_sanc	0.8230	0.363	2.269	0.029	0.089	1.557
Fin_sanc	-0.7469	0.237	-3.150	0.003	-1.227	-0.267
Tour_sanc	0.6857	0.285	2.402	0.021	0.108	1.264
Other_sanc	2.0108	0.674	2.983	0.005	0.646	3.375
Omnibus:	2.176	Durbin-Watson:	0.915			
Prob(Omnibus):	0.337	Jarque-Bera (JB):	2.062			
Skew:	0.491	Prob(JB):	0.357			
Kurtosis:	2.570	Cond. No.	588.			

Рис. 23. Итоговая оценка модели

Результаты модели показывают, что модель можно описать в том числе и без помощи интерсепта. При этом, военные и торговые санкции на цены на нефть не влияют. Это обуславливается тем, что очень многие стран очень сильно зависят от этого ресурса, в том числе и в военной сфере.

Рассмотрим пятую модель.

```
In [25]: res5 = smf.ols("IranGDP ~ Trade_sanc + War_sanc + Warcoop_sanc + Fin_sanc + Tour_sanc + Other_sanc", data=df5).fit()
res5.summary()
```

Out[25]: OLS Regression Results

Dep. Variable:	IranGDP	R-squared:	0.761			
Model:	OLS	Adj. R-squared:	0.721			
Method:	Least Squares	F-statistic:	19.11			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	7.35e-10			
Time:	13:23:51	Log-Likelihood:	-283.85			
No. Observations:	43	AIC:	581.7			
Df Residuals:	36	BIC:	594.0			
Df Model:	6					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	-247.2914	145.530	-1.699	0.098	-542.440	47.857
Trade_sanc	-1.6904	3.940	-0.429	0.670	-9.681	6.300
War_sanc	-18.2750	6.876	-2.658	0.012	-32.220	-4.329
Warcoop_sanc	10.7691	7.929	1.358	0.183	-5.312	26.851
Fin_sanc	3.3583	3.363	0.999	0.325	-3.462	10.179
Tour_sanc	3.8289	3.232	1.185	0.244	-2.725	10.383
Other_sanc	29.1591	7.997	3.646	0.001	12.940	45.378
Omnibus:	3.507	Durbin-Watson:	0.639			
Prob(Omnibus):	0.173	Jarque-Bera (JB):	2.608			
Skew:	0.286	Prob(JB):	0.271			
Kurtosis:	4.062	Cond. No.	733.			

Рис. 24. Первичная оценка модели

Как видно из результатов, многие признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [26]: res5 = smf.ols("IranGDP ~ War_sanc + Tour_sanc + Other_sanc", data=df5).fit()
res5.summary()
```

Out[26]:

OLS Regression Results

Dep. Variable:	IranGDP	R-squared:	0.745			
Model:	OLS	Adj. R-squared:	0.726			
Method:	Least Squares	F-statistic:	38.06			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	1.15e-11			
Time:	13:23:51	Log-Likelihood:	-285.21			
No. Observations:	43	AIC:	578.4			
Df Residuals:	39	BIC:	585.5			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	-204.1471	139.657	-1.462	0.152	-486.630	78.336
War_sanc	-9.4113	3.111	-3.025	0.004	-15.705	-3.118
Tour_sanc	7.0546	2.286	3.086	0.004	2.431	11.678
Other_sanc	29.3199	6.498	4.512	0.000	16.177	42.463
Omnibus:	5.456	Durbin-Watson:	0.616			
Prob(Omnibus):	0.065	Jarque-Bera (JB):	4.161			
Skew:	0.646	Prob(JB):	0.125			
Kurtosis:	3.808	Cond. No.	376.			

Рис. 25. Итоговая оценка модели

Иран уже давно находится под санкциями стран мира. За 42 года страна научилась функционировать в сложных экономических условиях. В стране сейчас работает собственная финансовая система, торговля ведется с помощью серых схем и т.д. Поэтому на ВВП Ирана влияют лишь некоторые санкции.

Рассмотрим шестую модель.

```
In [27]: res6 = smf.ols("SyrGDP ~ Trade_sanc + War_sanc + Warcoop_sanc + Fin_sanc + Tour_sanc + Other_sanc", data=df6).fit()
res6.summary()
```

Out[27]:

OLS Regression Results

Dep. Variable:	SyrGDP	R-squared:	0.616			
Model:	OLS	Adj. R-squared:	0.552			
Method:	Least Squares	F-statistic:	9.638			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	2.50e-06			
Time:	13:23:51	Log-Likelihood:	-216.39			
No. Observations:	43	AIC:	446.8			
Df Residuals:	36	BIC:	459.1			
Df Model:	6					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	96.6800	30.312	3.190	0.003	35.205	158.155
Trade_sanc	-1.5722	0.821	-1.916	0.063	-3.236	0.092
War_sanc	1.7322	1.432	1.210	0.234	-1.172	4.637
Warcoop_sanc	1.8373	1.652	1.112	0.273	-1.512	5.187
Fin_sanc	-2.9124	0.700	-4.158	0.000	-4.333	-1.492
Tour_sanc	2.2656	0.673	3.366	0.002	0.900	3.631
Other_sanc	2.9653	1.666	1.780	0.083	-0.413	6.343
Omnibus:	2.617	Durbin-Watson:	0.814			
Prob(Omnibus):	0.270	Jarque-Bera (JB):	1.602			
Skew:	0.413	Prob(JB):	0.449			
Kurtosis:	3.461	Cond. No.	733.			

Рис. 26. Первичная оценка модели

Как видно из результатов, некоторые признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [28]: res6 = smf.ols("SyrGDP ~ Trade_sanc + Warcoop_sanc + Fin_sanc + Tour_sanc + Other_sanc", data=df6).fit()
res6.summary()
```

Out[28]: OLS Regression Results

Dep. Variable:	SyrGDP	R-squared:	0.601			
Model:	OLS	Adj. R-squared:	0.547			
Method:	Least Squares	F-statistic:	11.13			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	1.36e-06			
Time:	13:23:51	Log-Likelihood:	-217.24			
No. Observations:	43	AIC:	446.5			
Df Residuals:	37	BIC:	457.1			
Df Model:	5					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	101.3948	30.247	3.352	0.002	40.108	162.682
Trade_sanc	-1.6147	0.825	-1.957	0.058	-3.286	0.057
Warcoop_sanc	3.5603	0.841	4.234	0.000	1.857	5.264
Fin_sanc	-2.6331	0.665	-3.957	0.000	-3.981	-1.285
Tour_sanc	2.0422	0.651	3.136	0.003	0.723	3.362
Other_sanc	2.9469	1.676	1.758	0.087	-0.449	6.343
Omnibus:	3.480	Durbin-Watson:	0.852			
Prob(Omnibus):	0.176	Jarque-Bera (JB):	2.310			
Skew:	0.478	Prob(JB):	0.315			
Kurtosis:	3.614	Cond. No.	681.			

Рис. 27. Итоговая оценка модели

Если сравнивать Сирию и Иран, то Сирия на данный момент не обладает теми характеристиками и системами, которые сейчас есть у Ирана. Поэтому на ВВП Сирии будут влиять почти все виды санкций.

Рассмотрим седьмую модель.

```
In [29]: res7 = smf.ols("VenGDP ~ Trade_sanc + War_sanc + Warcoop_sanc + Fin_sanc + Tour_sanc + Other_sanc", data=df7).fit()
res7.summary()
```

Out[29]: OLS Regression Results

Dep. Variable:	VenGDP	R-squared:	0.559			
Model:	OLS	Adj. R-squared:	0.486			
Method:	Least Squares	F-statistic:	7.620			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	2.52e-05			
Time:	13:23:51	Log-Likelihood:	-235.01			
No. Observations:	43	AIC:	484.0			
Df Residuals:	36	BIC:	496.3			
Df Model:	6					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	6.0699	46.743	0.130	0.897	-88.729	100.869
Trade_sanc	-1.1337	1.265	-0.896	0.376	-3.700	1.433
War_sanc	2.6390	2.209	1.195	0.240	-1.840	7.118
Warcoop_sanc	3.1228	2.547	1.226	0.228	-2.042	8.288
Fin_sanc	-3.4756	1.080	-3.218	0.003	-5.666	-1.285
Tour_sanc	1.1494	1.038	1.107	0.276	-0.956	3.254
Other_sanc	7.8800	2.569	3.068	0.004	2.671	13.089
Omnibus:	1.741	Durbin-Watson:	0.578			
Prob(Omnibus):	0.419	Jarque-Bera (JB):	0.912			
Skew:	0.306	Prob(JB):	0.634			
Kurtosis:	3.368	Cond. No.	733.			

Рис. 28. Первичная оценка модели

Как видно из результатов, многие признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [30]: res7 = smf.ols("VenGDP ~ Warcoop_sanc + Fin_sanc + Other_sanc", data=df7).fit()
res7.summary()
```

Out[30]: OLS Regression Results

Dep. Variable:	VenGDP	R-squared:	0.521			
Model:	OLS	Adj. R-squared:	0.484			
Method:	Least Squares	F-statistic:	14.12			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	2.21e-06			
Time:	13:23:51	Log-Likelihood:	-236.82			
No. Observations:	43	AIC:	481.6			
Df Residuals:	39	BIC:	488.7			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	-8.9371	31.812	-0.281	0.780	-73.282	55.408
Warcoop_sanc	6.0448	1.113	5.431	0.000	3.793	8.296
Fin_sanc	-3.1958	0.684	-4.669	0.000	-4.580	-1.811
Other_sanc	7.2464	2.309	3.139	0.003	2.577	11.916
Omnibus:	1.839	Durbin-Watson:	0.517			
Prob(Omnibus):	0.399	Jarque-Bera (JB):	0.951			
Skew:	-0.022	Prob(JB):	0.621			
Kurtosis:	3.727	Cond. No.	369.			

Рис. 29. Итоговая оценка модели

Венесуэла сегодня представляет довольно сложную страну. Развитие теневого сектора, рост насильственных преступлений не позволяют стране развиваться в социально-экономическом плане. А санкции, которые имеют под собой военное сотрудничество и финансы не позволяют стране победить преступность и наполнить бюджет.

Рассмотрим восьмую модель.

```
In [31]: res8 = smf.ols("RussiaGDP ~ Trade_sanc + War_sanc + Warcoop_sanc + Fin_sanc + Tour_sanc + Other_sanc", data=df8).fit()
res8.summary()
```

Out[31]: OLS Regression Results

Dep. Variable:	RussiaGDP	R-squared:	0.730			
Model:	OLS	Adj. R-squared:	0.685			
Method:	Least Squares	F-statistic:	16.25			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	6.00e-09			
Time:	13:23:51	Log-Likelihood:	-308.98			
No. Observations:	43	AIC:	632.0			
Df Residuals:	36	BIC:	644.3			
Df Model:	6					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	427.9393	261.077	1.639	0.110	-101.549	957.428
Trade_sanc	7.8543	7.068	1.111	0.274	-6.480	22.189
War_sanc	-23.7056	12.336	-1.922	0.063	-48.723	1.312
Warcoop_sanc	10.3447	14.225	0.727	0.472	-18.505	39.194
Fin_sanc	-8.9996	6.033	-1.492	0.144	-21.235	3.236
Tour_sanc	18.1891	5.797	3.137	0.003	6.431	29.947
Other_sanc	36.1341	14.347	2.519	0.016	7.038	65.230
Omnibus:	1.352	Durbin-Watson:	0.749			
Prob(Omnibus):	0.509	Jarque-Bera (JB):	0.684			
Skew:	0.284	Prob(JB):	0.710			
Kurtosis:	3.242	Cond. No.	733.			

Рис. 30. Первичная оценка модели

Как видно из результатов, многие признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель

```
In [32]: res8 = smf.ols("RussiaGDP ~ War_sanc + Tour_sanc + Other_sanc", data=df8).fit()
res8.summary()
```

Out[32]: OLS Regression Results

Dep. Variable:	RussiaGDP	R-squared:	0.703			
Model:	OLS	Adj. R-squared:	0.681			
Method:	Least Squares	F-statistic:	30.84			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	2.19e-10			
Time:	13:23:51	Log-Likelihood:	-311.02			
No. Observations:	43	AIC:	630.0			
Df Residuals:	39	BIC:	637.1			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	345.1458	254.539	1.356	0.183	-169.708	859.999
War_sanc	-17.9035	5.671	-3.157	0.003	-29.374	-6.433
Tour_sanc	16.1032	4.166	3.865	0.000	7.676	24.531
Other_sanc	34.8331	11.843	2.941	0.005	10.878	58.788
Omnibus:	2.066	Durbin-Watson:	0.611			
Prob(Omnibus):	0.356	Jarque-Bera (JB):	1.557			
Skew:	0.466	Prob(JB):	0.459			
Kurtosis:	3.002	Cond. No.	376.			

Рис. 31. Итоговая оценка модели

Россия же в отличие от других стран представляет собой уникальную модель страны. Торговые санкции не могут нанести существенного вреда экономике, поскольку Россия является важным игроком на мировом рынке, военное сотрудничество налажено со странами, которые не являются члена недружественных блоков, а финансовая система довольно быстро адаптируется к меняющимся условиям (в том числе, используя и серые схемы оплаты).

В значительной степени на ВВП России влияют военные санкции, которые направлены на изоляцию страны от высокотехнологичных элементов (например, процессоров), и туристические санкции, которые с одной стороны не позволяют части граждан спокойно путешествовать в некоторые страны, а с другой стороны открывают новые туристические направления.

Рассмотрим девятую модель.

```
In [33]: res9 = smf.ols("IranGDP ~ Oil_price + EU_gas_price + US_gas_price + Barl_Price", data=df9).fit()
res9.summary()
```

Out[33]: OLS Regression Results

Dep. Variable:	IranGDP	R-squared:	0.600			
Model:	OLS	Adj. R-squared:	0.558			
Method:	Least Squares	F-statistic:	14.25			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	3.40e-07			
Time:	13:23:51	Log-Likelihood:	-294.92			
No. Observations:	43	AIC:	599.8			
Df Residuals:	38	BIC:	608.6			
Df Model:	4					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	-48.7263	174.310	-0.280	0.781	-401.599	304.146
Oil_price	-1.3853	2.917	-0.475	0.638	-7.291	4.520
EU_gas_price	1.3124	0.366	3.590	0.001	0.572	2.053
US_gas_price	-0.9806	0.822	-1.193	0.240	-2.644	0.683
Barl_Price	0.8191	0.596	1.373	0.178	-0.388	2.026
Omnibus:	22.970	Durbin-Watson:	0.656			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	40.340			
Skew:	1.498	Prob(JB):	1.74e-09			
Kurtosis:	6.679	Cond. No.	2.50e+03			

Рис. 32. Первичная оценка модели

Как видно из результатов, многие признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [34]: res9 = smf.ols("IranGDP ~ EU_gas_price", data=df9).fit()
res9.summary()
```

Out[34]: OLS Regression Results

Dep. Variable:	IranGDP	R-squared:	0.542	
Model:	OLS	Adj. R-squared:	0.531	
Method:	Least Squares	F-statistic:	48.56	
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	1.83e-08	
Time:	13:23:51	Log-Likelihood:	-297.82	
No. Observations:	43	AIC:	599.6	
Df Residuals:	41	BIC:	603.2	
Df Model:	1			
Covariance Type:	nonrobust			
	coef	std err	t P> t [0.025 0.975]	
Intercept	99.5895	55.920	1.781 0.082	-13.343 212.522
EU_gas_price	1.5470	0.222	6.968 0.000	1.099 1.995
Omnibus:	33.758	Durbin-Watson:	0.574	
Prob(Omnibus):	0.000	Jarque-Bera (JB):	83.521	
Skew:	2.081	Prob(JB):	7.31e-19	
Kurtosis:	8.413	Cond. No.	366.	

Рис. 33. Итоговая оценка модели

ВВП Ирана уже давно не зависит от цен на нефть эталонной марки Brent. Также страна не зависит и от цен на газ в ЕС, а пшеница в стране производится самостоятельно. Основным фактором, который в будущем будет влиять на ВВП Ирана будет участие в проекте создания газового хаба в Турции, что также может привести к развитию страны.

Рассмотрим десятую модель.

```
In [35]: res10 = smf.ols("SyrGDP ~ Oil_price + EU_gas_price + US_gas_price + Barl_Price", data=df10).fit()
res10.summary()
```

Out[35]:

OLS Regression Results

Dep. Variable:	SyrGDP	R-squared:	0.502			
Model:	OLS	Adj. R-squared:	0.449			
Method:	Least Squares	F-statistic:	9.562			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	1.89e-05			
Time:	13:23:51	Log-Likelihood:	-222.01			
No. Observations:	43	AIC:	454.0			
Df Residuals:	38	BIC:	462.8			
Df Model:	4					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	-46.2820	31.986	-1.447	0.156	-111.034	18.470
Oil_price	-0.6477	0.535	-1.210	0.234	-1.731	0.436
EU_gas_price	-0.0795	0.067	-1.186	0.243	-0.215	0.056
US_gas_price	0.8069	0.151	5.351	0.000	0.502	1.112
Barl_Price	0.1496	0.109	1.367	0.180	-0.072	0.371
Omnibus:	38.710	Durbin-Watson:	0.886			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	119.533			
Skew:	2.298	Prob(JB):	1.11e-26			
Kurtosis:	9.752	Cond. No.	2.50e+03			

Рис. 34. Первичная оценка модели

Как видно из результатов, многие признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [36]: res10 = smf.ols("SyrGDP ~ US_gas_price", data=df10).fit()
res10.summary()
```

Out[36]:

OLS Regression Results

Dep. Variable:	SyrGDP	R-squared:	0.470			
Model:	OLS	Adj. R-squared:	0.457			
Method:	Least Squares	F-statistic:	36.38			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	3.90e-07			
Time:	13:23:51	Log-Likelihood:	-223.32			
No. Observations:	43	AIC:	450.6			
Df Residuals:	41	BIC:	454.2			
Df Model:	1					
Covariance Type:	nonrobust					
	coef	std err	t P> t [0.025 0.975]			
Intercept	-8.9415	14.095	-0.634	0.529	-37.406	19.523
US_gas_price	0.6715	0.111	6.032	0.000	0.447	0.896
Omnibus:	31.306	Durbin-Watson:	0.810			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	76.199			
Skew:	1.896	Prob(JB):	2.84e-17			
Kurtosis:	8.306	Cond. No.	262.			

Рис. 35. Итоговая оценка модели

Сирия сегодня сталкивается со многими вызовами со стороны, которые участвуют в военном конфликте на ее территории. Так в СМИ нередко появляется информация, которое свидетельствует о том, что из страны вывозят полезные ископаемые, в то время как страна находится в полуразрушенном состоянии. Такая деятельность хоть и является разрушительной, но и все равно может принести в ВВП некоторые потоки денежных средств.

Рассмотрим одинадцатую модель.

```
In [37]: res11 = smf.ols("VenGDP ~ Oil_price + EU_gas_price + US_gas_price + Bar1_Price", data=df11).fit()
res11.summary()
```

Out[37]: OLS Regression Results

Dep. Variable:	VenGDP	R-squared:	0.673			
Model:	OLS	Adj. R-squared:	0.638			
Method:	Least Squares	F-statistic:	19.53			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	8.35e-09			
Time:	13:23:51	Log-Likelihood:	-228.62			
No. Observations:	43	AIC:	467.2			
Df Residuals:	38	BIC:	476.0			
Df Model:	4					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	13.7640	37.301	0.369	0.714	-61.748	89.276
Oil_price	2.6639	0.624	4.268	0.000	1.400	3.928
EU_gas_price	-0.1365	0.078	-1.745	0.089	-0.295	0.022
US_gas_price	0.2265	0.176	1.288	0.205	-0.129	0.582
Bar1_Price	-0.0312	0.128	-0.244	0.808	-0.290	0.227
Omnibus:	3.207	Durbin-Watson:		0.605		
Prob(Omnibus):	0.201	Jarque-Bera (JB):		2.494		
Skew:	0.149	Prob(JB):		0.287		
Kurtosis:	4.142	Cond. No.		2.50e+03		

Рис. 36. Первичная оценка модели

Как видно из результатов, многие признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [38]: res11 = smf.ols("VenGDP ~ Oil_price + EU_gas_price + US_gas_price", data=df11).fit()
res11.summary()
```

Out[38]: OLS Regression Results

Dep. Variable:	VenGDP	R-squared:	0.672			
Model:	OLS	Adj. R-squared:	0.647			
Method:	Least Squares	F-statistic:	26.66			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	1.51e-09			
Time:	13:23:51	Log-Likelihood:	-228.65			
No. Observations:	43	AIC:	465.3			
Df Residuals:	39	BIC:	472.3			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	5.7023	17.136	0.333	0.741	-28.959	40.363
Oil_price	2.5423	0.371	6.847	0.000	1.791	3.293
EU_gas_price	-0.1475	0.063	-2.328	0.025	-0.276	-0.019
US_gas_price	0.2426	0.161	1.506	0.140	-0.083	0.568
Omnibus:	3.424	Durbin-Watson:	0.599			
Prob(Omnibus):	0.181	Jarque-Bera (JB):	2.867			
Skew:	0.118	Prob(JB):	0.238			
Kurtosis:	4.243	Cond. No.	603.			

Рис. 37. Итоговая оценка модели

Влияние неучтенных факторов в модели очень сильно влияет на другие показатели. В то же время, ВВП Венесуэлы зависит почти от всех цен на рассматриваемые товары. Экономике США и ЕС играют важную роль в

развитии страны, которая не только является довольно проблематичной страной, но и обладает значительными запасами минеральных ресурсов.

Рассмотрим двенадцатую модель.

```
In [39]: res12 = smf.ols("RussiaGDP ~ Oil_price + EU_gas_price + US_gas_price + Barl_Price", data=df12).fit()
res12.summary()
```

Out[39]: OLS Regression Results

Dep. Variable:	RussiaGDP	R-squared:	0.855			
Model:	OLS	Adj. R-squared:	0.840			
Method:	Least Squares	F-statistic:	56.04			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	1.99e-15			
Time:	13:23:51	Log-Likelihood:	-295.63			
No. Observations:	43	AIC:	601.3			
Df Residuals:	38	BIC:	610.1			
Df Model:	4					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	340.8626	177.211	1.923	0.062	-17.883	699.608
Oil_price	19.6493	2.966	6.626	0.000	13.646	25.653
EU_gas_price	0.2173	0.372	0.585	0.562	-0.535	0.970
US_gas_price	-2.8522	0.835	-3.414	0.002	-4.543	-1.161
Barl_Price	0.2101	0.606	0.347	0.731	-1.017	1.438
Omnibus:	1.614	Durbin-Watson:	0.605			
Prob(Omnibus):	0.446	Jarque-Bera (JB):	1.381			
Skew:	-0.279	Prob(JB):	0.501			
Kurtosis:	2.322	Cond. No.	2.50e+03			

Рис. 38. Первичная оценка модели

Как видно из результатов, некоторые признаки модели незначимы. Продолжим оптимизировать модель до тех пор, пока признаки не станут значимыми. В таком результате мы получим следующую модель.

```
In [40]: res12 = smf.ols("RussiaGDP ~ Oil_price + US_gas_price", data=df12).fit()
res12.summary()
```

Out[40]: OLS Regression Results

Dep. Variable:	RussiaGDP	R-squared:	0.851			
Model:	OLS	Adj. R-squared:	0.844			
Method:	Least Squares	F-statistic:	114.3			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	2.87e-17			
Time:	13:23:51	Log-Likelihood:	-296.20			
No. Observations:	43	AIC:	598.4			
Df Residuals:	40	BIC:	603.7			
Df Model:	2					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	386.2711	80.880	4.776	0.000	222.806	549.736
Oil_price	21.3698	1.499	14.257	0.000	18.340	24.399
US_gas_price	-2.7682	0.739	-3.747	0.001	-4.261	-1.275
Omnibus:	1.823	Durbin-Watson:	0.596			
Prob(Omnibus):	0.402	Jarque-Bera (JB):	1.357			
Skew:	-0.217	Prob(JB):	0.507			
Kurtosis:	2.245	Cond. No.	292			

Рис. 39. Итоговая оценка модели

ВВП России очень сильно зависит от мировых цен на нефть. В то же время, ВВП России зависит и от цен на газ в США. Это можно объяснить следующим образом. Газ из США является альтернативой газу России в сфере поставок в Европу и другие страны. Таким образом, сейчас ВВП России и получает какие-

либо значительные поступления в бюджет от продажи газа в ЕС, но санкции могут ограничивать такую деятельность.

Таким образом, мы рассмотрели 12 моделей влияния санкций на ВВП выбранных стран, а также на цены на биржевые товары. В целом, множественная линейная регрессия достаточно хорошо описывает данные процессы. Однако специфика данного анализа заключается в том, что санкции являются долгосрочными факторами.

Так, например, критерий Дарбина-Уотсона часто говорит об автокорреляции первого порядка элементов исследуемой последовательности, а именно отрицательной автокорреляции. Далее стоит провести с моделями ряд параметрических и непараметрических тестов, а также посмотреть на сложные эконометрические модели для данного исследования.

Хотя линейная регрессия и дает в целом хорошие модели, стоит построить нелинейные модели для некоторых из них. Возможно, это даст нам более подходящие модели.

Построение моделей – использование нелинейной регрессии.

Графики `pairplot`, построенные ранее показывают, что некоторые признаки могут иметь нелинейную связь между собой. Так, некоторые признаки, согласно первичному анализу могут иметь полиномиальную связь.

Поэтому стоит рассмотреть построение регрессии с использованием полиномиальной регрессии путем введения степенной функции.

При построении моделей выяснилось, что применение такой регрессии к моделям 10 и 12 приводит к значительному ухудшению моделей. Поэтому было принято решение отказаться от использования полиномиальной регрессии к данным моделям.

```
In [53]: res1 = smf.ols("Barl_Price ~ I(War_sanc**2) + I(Warcoop_sanc**2) + Other_sanc", data=df1).fit()  
res1.summary()
```

Out[53]: OLS Regression Results

Dep. Variable:	Barl_Price	R-squared:	0.678			
Model:	OLS	Adj. R-squared:	0.653			
Method:	Least Squares	F-statistic:	27.37			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	1.07e-09			
Time:	14:07:24	Log-Likelihood:	-255.10			
No. Observations:	43	AIC:	518.2			
Df Residuals:	39	BIC:	525.2			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	143.2074	59.088	2.424	0.020	23.691	262.724
I(War_sanc ** 2)	-0.0632	0.028	-2.276	0.028	-0.119	-0.007
I(Warcoop_sanc ** 2)	0.1143	0.040	2.824	0.007	0.032	0.196
Other_sanc	10.3899	3.229	3.218	0.003	3.859	16.921
Omnibus:	18.648	Durbin-Watson:	0.878			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	26.258			
Skew:	1.333	Prob(JB):	1.99e-06			
Kurtosis:	5.747	Cond. No.	1.70e+04			

Рис. 40. Нелинейная регрессия первой модели

```
In [61]: res3 = smf.ols("US_gas_price ~ I(Warcoop_sanc**2) + Fin_sanc + Tour_sanc", data=df3).fit()
res3.summary()
```

Out[61]: OLS Regression Results

Dep. Variable:	US_gas_price	R-squared:	0.595			
Model:	OLS	Adj. R-squared:	0.564			
Method:	Least Squares	F-statistic:	19.13			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	8.64e-08			
Time:	14:30:44	Log-Likelihood:	-218.43			
No. Observations:	43	AIC:	444.9			
Df Residuals:	39	BIC:	451.9			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	215.1169	22.992	9.356	0.000	168.611	261.622
I(Warcoop_sanc ** 2)	0.0544	0.013	4.221	0.000	0.028	0.081
Fin_sanc	-3.2763	0.508	-6.445	0.000	-4.304	-2.248
Tour_sanc	2.0658	0.656	3.149	0.003	0.739	3.393
Omnibus:	10.961	Durbin-Watson:	1.175			
Prob(Omnibus):	0.004	Jarque-Bera (JB):	10.802			
Skew:	0.990	Prob(JB):	0.00451			
Kurtosis:	4.451	Cond. No.	8.89e+03			

Рис. 41. Нелинейная регрессия третьей модели

```
In [64]: res4 = smf.ols("Oil_price ~ I(Warcoop_sanc**2) + Fin_sanc + Tour_sanc + Other_sanc", data=df4).fit()
res4.summary()
```

Out[64]: OLS Regression Results

Dep. Variable:	Oil_price	R-squared:	0.711			
Model:	OLS	Adj. R-squared:	0.681			
Method:	Least Squares	F-statistic:	23.40			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	8.14e-10			
Time:	14:31:49	Log-Likelihood:	-180.75			
No. Observations:	43	AIC:	371.5			
Df Residuals:	38	BIC:	380.3			
Df Model:	4					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	24.5157	12.067	2.032	0.049	0.086	48.945
I(Warcoop_sanc ** 2)	0.0165	0.005	3.002	0.005	0.005	0.028
Fin_sanc	-0.8020	0.229	-3.506	0.001	-1.265	-0.339
Tour_sanc	0.5827	0.277	2.105	0.042	0.022	1.143
Other_sanc	1.4711	0.643	2.288	0.028	0.169	2.773
Omnibus:	1.128	Durbin-Watson:	0.960			
Prob(Omnibus):	0.569	Jarque-Bera (JB):	0.985			
Skew:	0.356	Prob(JB):	0.611			
Kurtosis:	2.795	Cond. No.	1.11e+04			

Рис. 42. Нелинейная регрессия четвертой модели

```
In [73]: res6 = smf.ols("SyrGDP ~ I(Warcoop_sanc**0.5) + Fin_sanc + Tour_sanc", data=df6).fit()
res6.summary()
```

Out[73]: OLS Regression Results

Dep. Variable:	SyrGDP	R-squared:	0.596			
Model:	OLS	Adj. R-squared:	0.564			
Method:	Least Squares	F-statistic:	19.14			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	8.61e-08			
Time:	14:34:20	Log-Likelihood:	-217.52			
No. Observations:	43	AIC:	443.0			
Df Residuals:	39	BIC:	450.1			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	40.8652	35.657	1.146	0.259	-31.257	112.988
I(Warcoop_sanc ** 0.5)	33.3187	7.526	4.427	0.000	18.096	48.541
Fin_sanc	-3.1108	0.470	-6.616	0.000	-4.062	-2.160
Tour_sanc	2.4158	0.599	4.036	0.000	1.205	3.626
Omnibus:	6.338	Durbin-Watson:	0.674			
Prob(Omnibus):	0.042	Jarque-Bera (JB):	5.181			
Skew:	0.661	Prob(JB):	0.0750			
Kurtosis:	4.069	Cond. No.	667.			

Рис. 43. Нелинейная регрессия шестой модели

```
In [75]: res7 = smf.ols("VenGDP ~ Trade_sanc + I(War_sanc**2) + I(Warcoop_sanc**2) + Fin_sanc + Other_sanc", data=df7).fit()
res7.summary()
```

Out[75]: OLS Regression Results

Dep. Variable:	VenGDP	R-squared:	0.582			
Model:	OLS	Adj. R-squared:	0.525			
Method:	Least Squares	F-statistic:	10.29			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	3.07e-06			
Time:	14:35:05	Log-Likelihood:	-233.90			
No. Observations:	43	AIC:	479.8			
Df Residuals:	37	BIC:	490.4			
Df Model:	5					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	162.7720	39.853	4.084	0.000	82.023	243.521
Trade_sanc	-4.0309	1.354	-2.976	0.005	-6.775	-1.287
I(War_sanc ** 2)	0.0367	0.019	1.945	0.059	-0.002	0.075
I(Warcoop_sanc ** 2)	0.0722	0.026	2.747	0.009	0.019	0.126
Fin_sanc	-2.2991	0.814	-2.824	0.008	-3.948	-0.650
Other_sanc	7.0309	2.435	2.888	0.006	2.098	11.964
Omnibus:	1.584	Durbin-Watson:	0.565			
Prob(Omnibus):	0.453	Jarque-Bera (JB):	0.880			
Skew:	0.329	Prob(JB):	0.644			
Kurtosis:	3.239	Cond. No.	1.83e+04			

Рис. 44. Нелинейная регрессия седьмой модели

```
In [79]: res8 = smf.ols("RussiaGDP ~ War_sanc + Tour_sanc + I(Other_sanc**2)", data=df8).fit()
res8.summary()
```

Out[79]: OLS Regression Results

Dep. Variable:	RussiaGDP	R-squared:	0.681			
Model:	OLS	Adj. R-squared:	0.657			
Method:	Least Squares	F-statistic:	27.78			
Date:	Wed, 16 Nov 2022	Prob (F-statistic):	8.80e-10			
Time:	14:36:30	Log-Likelihood:	-312.57			
No. Observations:	43	AIC:	633.1			
Df Residuals:	39	BIC:	640.2			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	832.1627	177.700	4.683	0.000	472.731	1191.594
War_sanc	-17.2629	5.880	-2.936	0.006	-29.156	-5.370
Tour_sanc	17.8598	4.209	4.243	0.000	9.346	26.374
I(Other_sanc ** 2)	0.4032	0.175	2.310	0.026	0.050	0.756
Omnibus:	2.471	Durbin-Watson:	0.521			
Prob(Omnibus):	0.291	Jarque-Bera (JB):	1.871			
Skew:	0.510	Prob(JB):	0.392			
Kurtosis:	3.043	Cond. No.	2.83e+03			

Рис. 45. Нелинейная регрессия восьмой модели

Построение моделей с фиктивными переменными.

Далее стоит рассмотреть модели с фиктивными переменными. Фиктивные переменные позволят учесть различные факторы, которые влияют на анализ данных.

Так были введены фиктивные переменные по четырем состояниям стран. Сюда входят военные конфликты, политические и экономические кризисы и социальная напряженность. В каждом году странам были присвоены бинарные значения. Так ниже представлена общая таблица.

```
In [9]: df.head()
```

Out[9]:

yrGDP	Oil_price	EU_gas_price	US_gas_price	Bart_Price	Trade_sanc	...	IranSoc	IranEc	RusWar	RusPol	RusSoc	RusEc	VenWar	VenPol	VenSoc	VenEc
13.06	37.89	137.6	51.80	441.36	33	...	1	1	1	1	1	0	0	1	1	1
16.76	36.68	150.0	64.65	395.44	35	...	0	1	1	0	0	0	0	1	1	1
17.53	33.42	145.1	80.36	338.52	41	...	0	1	1	0	0	0	0	0	1	1
18.67	29.55	132.0	84.51	354.40	37	...	0	1	1	0	0	0	0	0	1	1
19.20	28.28	122.6	86.54	355.00	35	...	1	0	1	0	0	0	0	0	1	1

Рис. 46. Анализируемые данные с фиктивными переменными

Теперь рассмотрим модели, которые учитывают одновременно и санкции в отношении стран, так и их состояния.

Для отбора моделей используем язык программирования R.

Так построим необходимые модели в нем, а также построим линейную регрессию.

Также функцией stepAIC, которая отбирает признаки на основе критерия Акаике - критерий, применяющийся исключительно для выбора из нескольких

статистических моделей. И на основе этого критерия отберем значимые критерии.

```
1 df = Fict
2 df1 = lm(Barl_Price ~ Trade_sanc + war_sanc + warcoop_sanc + Fin_sanc +
3         Tour_sanc + Other_sanc + SyrPol + SyrSoc+ SyrEc+ IranWar+
4         IranPol+ IranSoc+ IranEc + RusWar+ RusPol + RusSoc+ RusEc+ VenWar+
5         VenPol+ VenSoc+ VenEc, df)
6 summary(df1)
7 ss = stepAIC(df1)
8 df2 = lm(Barl_Price ~ War_sanc + warcoop_sanc + Other_sanc + SyrSoc +
9         IranWar + IranSoc + RusWar + RusPol + VenSoc + VenEc, df)
10 summary(df2)
11
12 df3 = lm(Oil_price ~ Trade_sanc + war_sanc + warcoop_sanc + Fin_sanc +
13         Tour_sanc + Other_sanc + SyrPol + SyrSoc+ SyrEc+ IranWar+
14         IranPol+ IranSoc+ IranEc + RusWar+ RusPol + RusSoc+ RusEc+ VenWar+
15         VenPol+ VenSoc+ VenEc, df)
16 summary(df3)
17 ss1 = stepAIC(df3)
18 df4 = lm(Oil_price ~ War_sanc + warcoop_sanc + Tour_sanc + Other_sanc +
19         IranWar + RusWar + VenSoc + VenEc, df)
20 summary(df4)
21
22 df5 = lm(EU_gas_price ~ Trade_sanc + war_sanc + warcoop_sanc + Fin_sanc +
23         Tour_sanc + Other_sanc + SyrPol + SyrSoc+ SyrEc+ IranWar+
24         IranPol+ IranSoc+ IranEc + RusWar+ RusPol + RusSoc+ RusEc+ VenWar+
25         VenPol+ VenSoc+ VenEc, df)
26 summary(df5)
27 ss1 = stepAIC(df5)
28 df6 = lm(EU_gas_price ~ Trade_sanc + War_sanc + warcoop_sanc + Tour_sanc +
29         other_sanc + IranSoc + IranEc + RusSoc + VenPol + VenSoc +
30         VenEc, df)
31 summary(df6)
32
33
34 df7 = lm(US_gas_price ~ Trade_sanc + War_sanc + warcoop_sanc + Fin_sanc +
35         Tour_sanc + Other_sanc + SyrPol + SyrSoc+ SyrEc+ IranWar+
36         IranPol+ IranSoc+ IranEc + RusWar+ RusPol + RusSoc+ RusEc+ VenWar+
37         VenPol+ VenSoc+ VenEc, df)
38 summary(df7)
39 ss1 = stepAIC(df7)
40 df8 = lm(US_gas_price ~ War_sanc + warcoop_sanc + SyrPol + SyrSoc + IranWar +
41         IranPol + IranSoc + venSoc, df)
42 summary(df8)
43
```

Рис. 47. Модели с фиктивными переменными в R

Таким образом, мы смогли получить уже первично отобранные признаки из порядка 20 первичных признаков.

Таким образом, с помощью фиктивных переменных удалось построить следующие модели.


```

Call:
lm(formula = Barl_Price ~ war_sanc + warcoop_sanc + Other_sanc +
    syrSoc + IranWar + IranSoc + RusWar + RusPol + VenSoc + VenEc,
    data = df)

Residuals:
    Min       1Q   Median       3Q      Max
-142.031  -54.927    8.046   44.791  194.871

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   128.539     64.618   1.989  0.05528 .
war_sanc       -4.875      3.028  -1.610  0.11719
warcoop_sanc    6.426      3.166   2.030  0.05075 .
Other_sanc      9.811      3.089   3.176  0.00330 **
syrSoc         48.821     35.017   1.394  0.17285
IranWar       157.606     44.487   3.543  0.00124 **
IranSoc       -44.210     34.425  -1.284  0.20828
RusWar       -48.345     38.792  -1.246  0.22171
RusPol        106.521     38.790   2.746  0.00981 **
VenSoc       -194.143     63.109  -3.076  0.00427 **
VenEc         117.454     70.019   1.677  0.10320
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 78.56 on 32 degrees of freedom
Multiple R-squared:  0.8224,    Adjusted R-squared:  0.7669
F-statistic: 14.82 on 10 and 32 DF,  p-value: 2.285e-09

```

Рис. 48. Модель влияния факторов на цену пшеницы с фиктивными переменными в R

```

Call:
lm(formula = oil_price ~ war_sanc + warcoop_sanc + Tour_sanc +
    other_sanc + IranWar + RusWar + VenSoc + VenEc, data = df)

Residuals:
    Min       1Q   Median       3Q      Max
-20.714  -7.449    3.262    6.599   22.196

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -10.4037     16.8958  -0.616  0.54216
war_sanc      -0.7011      0.4458  -1.573  0.12502
warcoop_sanc   1.8741      0.5295   3.539  0.00118 **
Tour_sanc     -0.3538      0.2406  -1.470  0.15070
Other_sanc     1.1041      0.5570   1.982  0.05558 .
IranWar       31.2071      6.3247   4.934 2.09e-05 ***
RusWar       -17.0173      6.7363  -2.526  0.01635 *
VenSoc       -23.3380      9.6027  -2.430  0.02051 *
VenEc        19.8716     10.4373   1.904  0.06542 .
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.7 on 34 degrees of freedom
Multiple R-squared:  0.8596,    Adjusted R-squared:  0.8266
F-statistic: 26.02 on 8 and 34 DF,  p-value: 2.378e-12

```

Рис. 49. Модель влияния факторов на цену нефти с фиктивными переменными в R

```

Call:
lm(formula = EU_gas_price ~ Trade_sanc + war_sanc + warcoop_sanc +
    Tour_sanc + Other_sanc + IranSoc + IranEc + RusSoc + VenPol +
    VenSoc + VenEc, data = df)

Residuals:
    Min       1Q   Median       3Q      Max
-145.75  -38.92   14.06   37.34  145.75

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -275.117    64.988  -4.233 0.000190 ***
Trade_sanc      8.887     1.536   5.787 2.25e-06 ***
war_sanc     -9.139     2.956  -3.091 0.004188 **
warcoop_sanc   4.845     3.041   1.593 0.121252
Tour_sanc     -5.909     1.325  -4.458 0.000101 ***
Other_sanc    21.543     3.398   6.340 4.68e-07 ***
IranSoc      103.711    30.354   3.417 0.001790 **
IranEc       56.784    34.684   1.637 0.111705
RusSoc      -50.366    27.820  -1.810 0.079933 .
VenPol       79.217    28.644   2.766 0.009487 **
VenSoc     -394.919    70.135  -5.631 3.52e-06 ***
VenEc      123.445     63.371   1.948 0.060520 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 71.78 on 31 degrees of freedom
Multiple R-squared:  0.8764,    Adjusted R-squared:  0.8326
F-statistic: 19.99 on 11 and 31 DF,  p-value: 4.324e-11

```

Рис. 49. Модель влияния факторов на цену газа в ЕС с фиктивными переменными в R

```

Call:
lm(formula = US_gas_price ~ war_sanc + warcoop_sanc + SyrPol +
    syrSoc + IranWar + IranPol + IranSoc + VenSoc, data = df)

Residuals:
    Min       1Q   Median       3Q      Max
-70.535 -15.727  -1.158  14.776  80.775

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   79.174    17.689   4.476 8.12e-05 ***
war_sanc      -2.709     1.226  -2.210 0.033904 *
warcoop_sanc   4.884     1.306   3.740 0.000678 ***
SyrPol       -21.807    14.146  -1.542 0.132442
SyrSoc       -32.245    13.872  -2.324 0.026207 *
IranWar       52.575    12.288   4.279 0.000145 ***
IranPol      -25.121    18.116  -1.387 0.174567
IranSoc       23.998    14.262   1.683 0.101614
VenSoc       -60.621    12.585  -4.817 2.96e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 31.24 on 34 degrees of freedom
Multiple R-squared:  0.7936,    Adjusted R-squared:  0.745
F-statistic: 16.34 on 8 and 34 DF,  p-value: 1.332e-09

```

Рис. 50. Модель влияния факторов на цену газа в США с фиктивными переменными в R

Таким образом, данные модели позволяют отобрать некоторые значимые признаки и построить линейную регрессию с учетом фиктивных переменных.

Модель ARIMA для временных рядов цен на пшеницу, нефть и газ.

Временные ряды цен выбранных товаров являются нестационарными. Это легко проверить путем построения простых графиков.

Модель ARIMA использует три целочисленных параметра: p , d и q .

p — порядок авторегрессии (AR). Его можно интерпретировать как выражение «элемент ряда будет близок к X , если предыдущие p элементов были близки к X ».

d — порядок интегрирования (разностей исходного временного ряда). Можно понимать как «элемент будет близок по значению к предыдущим d элементам, если их разность минимальна».

q — порядок скользящего среднего (MA), который позволяет установить погрешность модели как линейную комбинацию наблюдавшихся ранее значений ошибок.

Образуем таблицы для анализа.

```
In [65]: df1 = df["Bar1_Price"]
df2 = df["Oil_price"]
df3 = df["EU_gas_price"]
df4 = df["US_gas_price"]
```

Рис. 51. Таблицы для построение модели ARIMA

Нахождение параметров ARIMA для каждого из рядов произведем следующим программным кодом.

```
In [61]: import warnings
import itertools
from statsmodels.tsa.arima.model import ARIMA
warnings.filterwarnings("ignore")

p = range(0,10)
d = q = range(0,3)
pdq = list(itertools.product(p, d, q))
best_pdq = (0,0,0)
best_aic = np.inf
for params in pdq:
    model_test = ARIMA(df1, order = params)
    result_test = model_test.fit()
    if result_test.aic < best_aic:
        best_pdq = params
        best_aic = result_test.aic
print(best_pdq, best_aic)
```

Рис. 52. Программный код для нахождения ARIMA для первой модели

```
In [63]: import warnings
import itertools
from statsmodels.tsa.arima.model import ARIMA
warnings.filterwarnings("ignore")

p = range(0,10)
d = q = range(0,3)
pdq = list(itertools.product(p, d, q))
best_pdq = (0,0,0)
best_aic = np.inf
for params in pdq:
    model_test = ARIMA(df2, order = params)
    result_test = model_test.fit()
    if result_test.aic < best_aic:
        best_pdq = params
        best_aic = result_test.aic
print(best_pdq, best_aic)
```

Рис. 53. Программный код для нахождения ARIMA для второй модели

```
In [64]: import warnings
import itertools
from statsmodels.tsa.arima.model import ARIMA
warnings.filterwarnings("ignore")

p = range(0,10)
d = q = range(0,3)
pdq = list(itertools.product(p, d, q))
best_pdq = (0,0,0)
best_aic = np.inf
for params in pdq:
    model_test = ARIMA(df3, order = params)
    result_test = model_test.fit()
    if result_test.aic < best_aic:
        best_pdq = params
        best_aic = result_test.aic
print(best_pdq, best_aic)
```

Рис. 54. Программный код для нахождения ARIMA для третьей модели

```
In [66]: import warnings
import itertools
from statsmodels.tsa.arima.model import ARIMA
warnings.filterwarnings("ignore")

p = range(0,10)
d = q = range(0,3)
pdq = list(itertools.product(p, d, q))
best_pdq = (0,0,0)
best_aic = np.inf
for params in pdq:
    model_test = ARIMA(df4, order = params)
    result_test = model_test.fit()
    if result_test.aic < best_aic:
        best_pdq = params
        best_aic = result_test.aic
print(best_pdq, best_aic)
```

Рис. 55. Программный код для нахождения ARIMA для четвертой модели

Таким образом, для каждой модели были получены следующие параметры модели ARIMA и параметры AIC.

Таблица 1

Параметры ARIMA для моделей

Модель	Параметры	AIC
1	(0, 2, 2)	487.45875589496535
2	(0, 2, 1)	345.6908553634801
3	(0, 2, 0)	513.8015114435941
4	(2, 2, 2)	427.7221159440755

Построение моделей ARIMA произведем по следующему программному коду для каждой из моделей.

Построение ARIMA

```
In [146]: model1 = ARIMA(df1, order=(0, 2, 2))
result1 = model1.fit()
```

```
In [147]: model2 = ARIMA(df2, order=(0, 2, 1))
result2 = model2.fit()
```

```
In [148]: model3 = ARIMA(df3, order=(0, 2, 0))
result3 = model3.fit()
```

```
In [149]: model4 = ARIMA(df4, order=(2, 2, 2))
result4 = model4.fit()
```

Рис. 56. Построение моделей ARIMA

```
In [150]: result1.summary()
```

```
Out[150]:
```

SARIMAX Results

Dep. Variable:	Bart_Price	No. Observations:	43			
Model:	ARIMA(0, 2, 2)	Log Likelihood	-240.729			
Date:	Wed, 16 Nov 2022	AIC	487.459			
Time:	17:53:10	BIC	492.599			
Sample:	01-01-1970	HQIC	489.331			
	- 01-01-1970					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
ma.L1	-0.5216	2.589	-0.201	0.840	-5.595	4.552
ma.L2	-0.4758	1.260	-0.378	0.706	-2.945	1.994
sigma2	6832.2222	1.76e+04	0.387	0.699	-2.77e+04	4.14e+04
Ljung-Box (L1) (Q):	0.20	Jarque-Bera (JB):	0.76			
Prob(Q):	0.65	Prob(JB):	0.69			
Heteroskedasticity (H):	1.76	Skew:	-0.02			
Prob(H) (two-sided):	0.30	Kurtosis:	3.66			

```
In [157]: result1.plot_diagnostics(figsize=(12, 8))
plt.show()
```

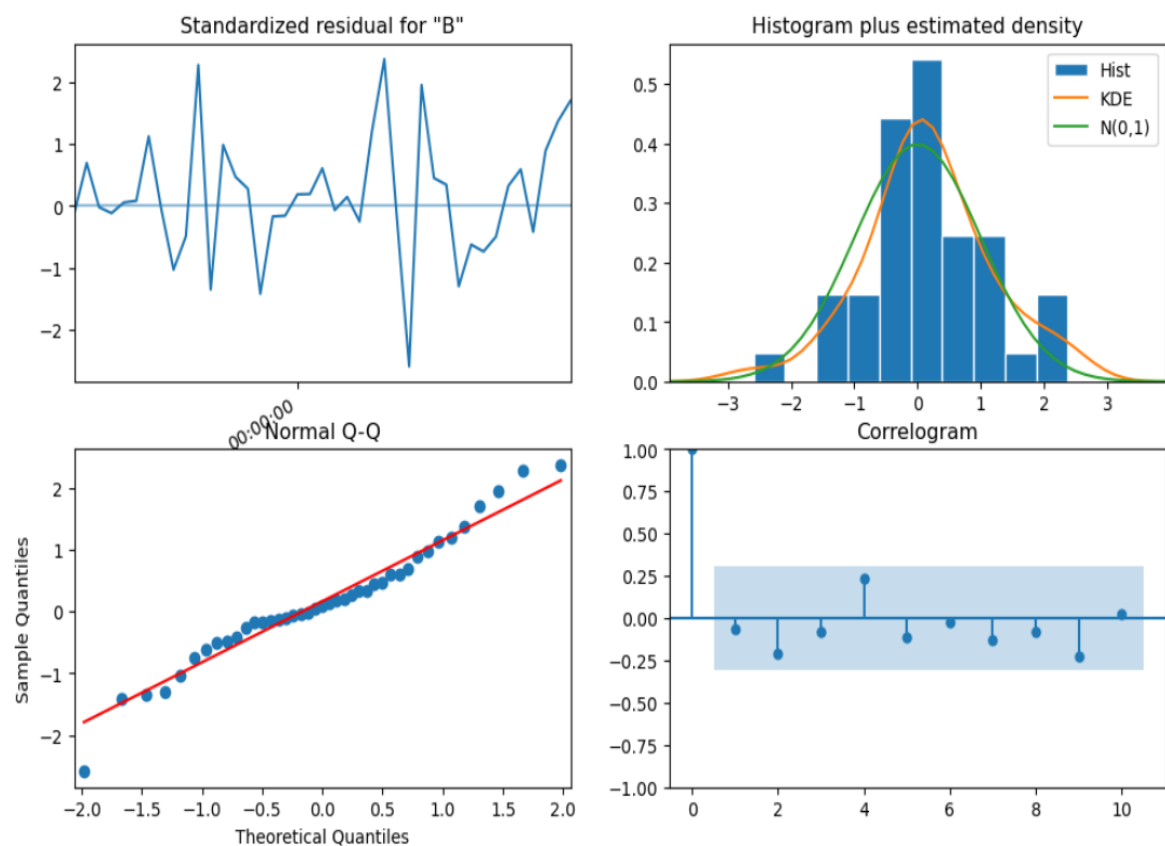


Рис. 57. Данные и проверка первой модели ARIMA

```
In [151]: result2.summary()
```

Out[151]:

SARIMAX Results

Dep. Variable:	Oil_price	No. Observations:	43			
Model:	ARIMA(0, 2, 1)	Log Likelihood	-170.845			
Date:	Wed, 16 Nov 2022	AIC	345.691			
Time:	17:53:10	BIC	349.118			
Sample:	01-01-1970	HQIC	346.939			
	- 01-01-1970					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
ma.L1	-0.9983	2.251	-0.444	0.657	-5.410	3.413
sigma2	222.8796	512.435	0.435	0.664	-781.475	1227.235
Ljung-Box (L1) (Q):	0.02	Jarque-Bera (JB):	17.70			
Prob(Q):	0.88	Prob(JB):	0.00			
Heteroskedasticity (H):	28.66	Skew:	-0.85			
Prob(H) (two-sided):	0.00	Kurtosis:	5.73			

```
In [160]: result2.plot_diagnostics(figsize=(12, 8))
plt.show()
```

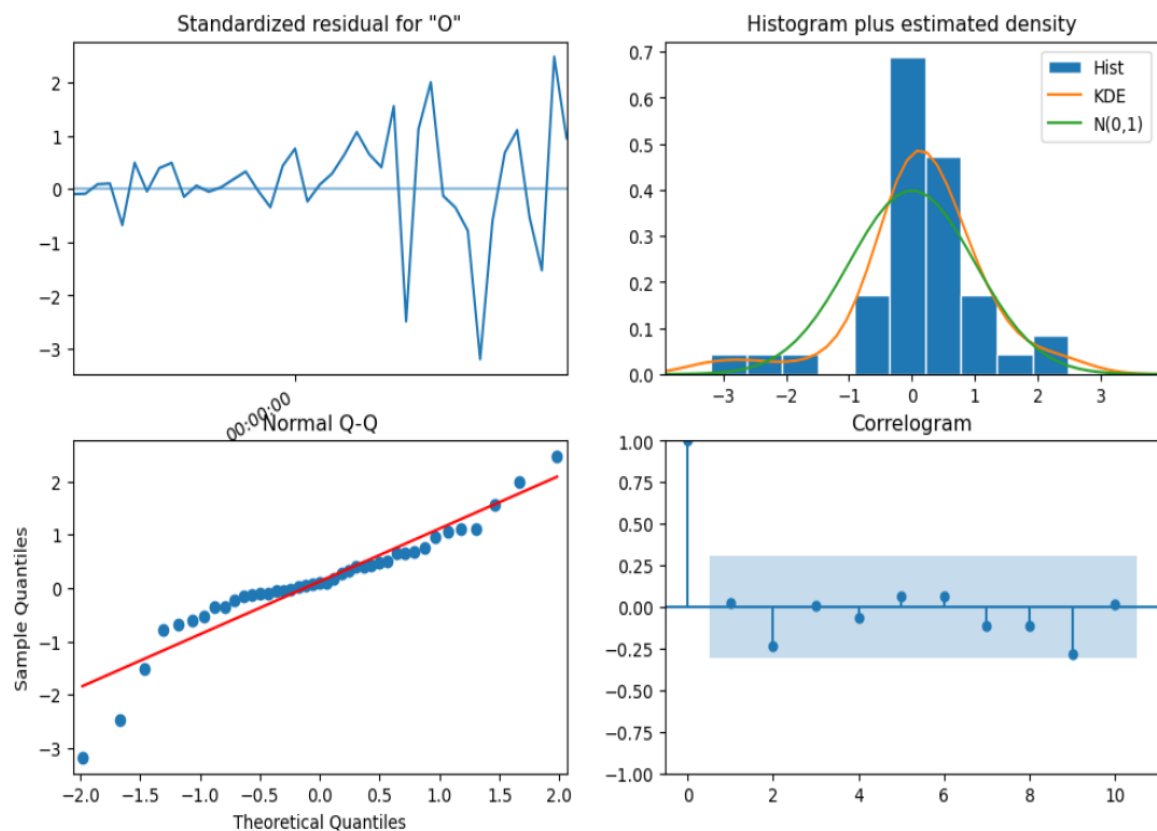


Рис. 58. Данные и проверка второй модели ARIMA

In [152]: `result3.summary()`

Out[152]: SARIMAX Results

Dep. Variable:	EU_gas_price	No. Observations:	43			
Model:	ARIMA(0, 2, 0)	Log Likelihood	-255.901			
Date:	Wed, 16 Nov 2022	AIC	513.802			
Time:	17:53:10	BIC	515.515			
Sample:	01-01-1970	HQIC	514.425			
	- 01-01-1970					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
sigma2	1.544e+04	1399.288	11.038	0.000	1.27e+04	1.82e+04
Ljung-Box (L1) (Q):	0.18	Jarque-Bera (JB):	169.04			
Prob(Q):	0.67	Prob(JB):	0.00			
Heteroskedasticity (H):	110.75	Skew:	1.95			
Prob(H) (two-sided):	0.00	Kurtosis:	12.15			

In [159]: `result3.plot_diagnostics(figsize=(12, 8))`
`plt.show()`

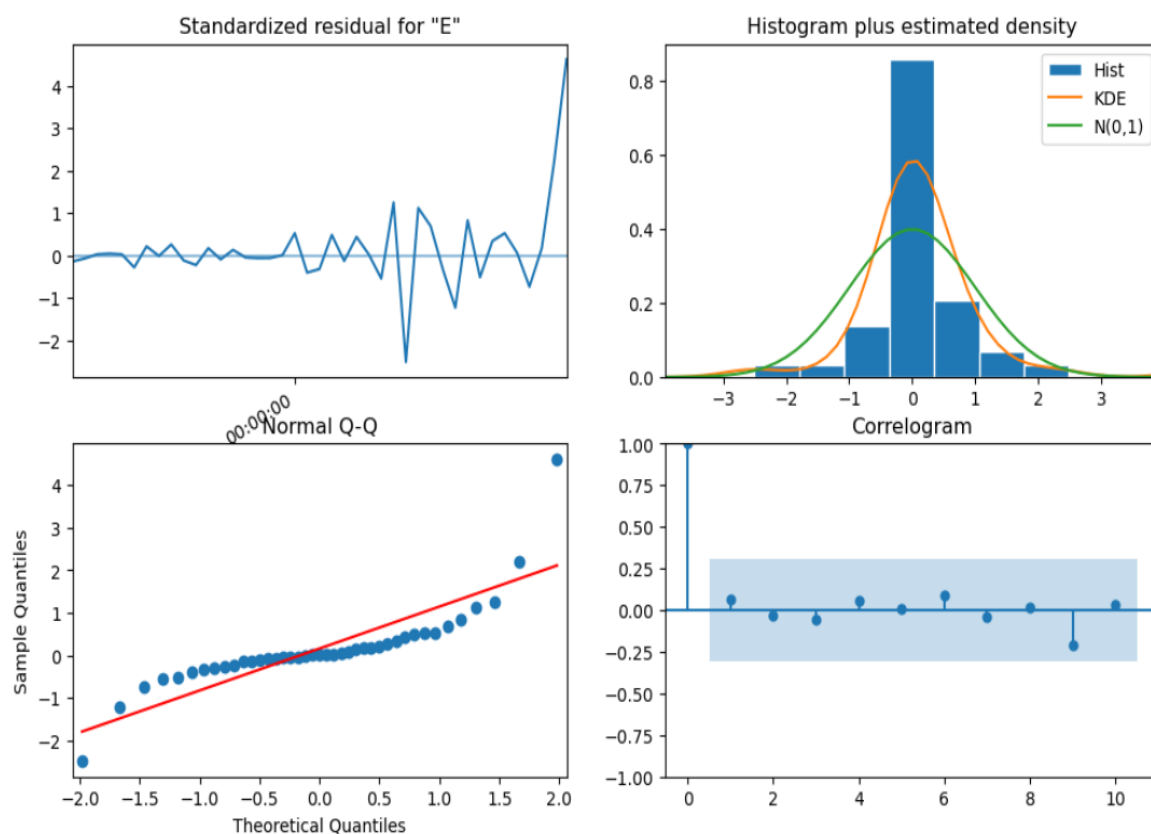


Рис. 59. Данные и проверка третьей модели ARIMA

```
In [153]: result4.summary()
```

```
Out[153]:
```

SARIMAX Results

Dep. Variable:	US_gas_price	No. Observations:	43			
Model:	ARIMA(2, 2, 2)	Log Likelihood	-208.861			
Date:	Wed, 16 Nov 2022	AIC	427.722			
Time:	17:53:10	BIC	436.290			
Sample:	01-01-1970	HQIC	430.842			
	- 01-01-1970					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
ar.L1	-1.0277	0.149	-6.879	0.000	-1.321	-0.735
ar.L2	-0.3770	0.155	-2.429	0.015	-0.681	-0.073
ma.L1	-0.0029	61.874	-4.63e-05	1.000	-121.274	121.269
ma.L2	-0.9970	62.623	-0.016	0.987	-123.736	121.742
sigma2	1319.8859	8.28e+04	0.016	0.987	-1.61e+05	1.64e+05
Ljung-Box (L1) (Q):	0.00	Jarque-Bera (JB):	5.08			
Prob(Q):	1.00	Prob(JB):	0.08			
Heteroskedasticity (H):	24.23	Skew:	-0.11			
Prob(H) (two-sided):	0.00	Kurtosis:	4.71			

```
In [158]: result4.plot_diagnostics(figsize=(12, 8))
plt.show()
```

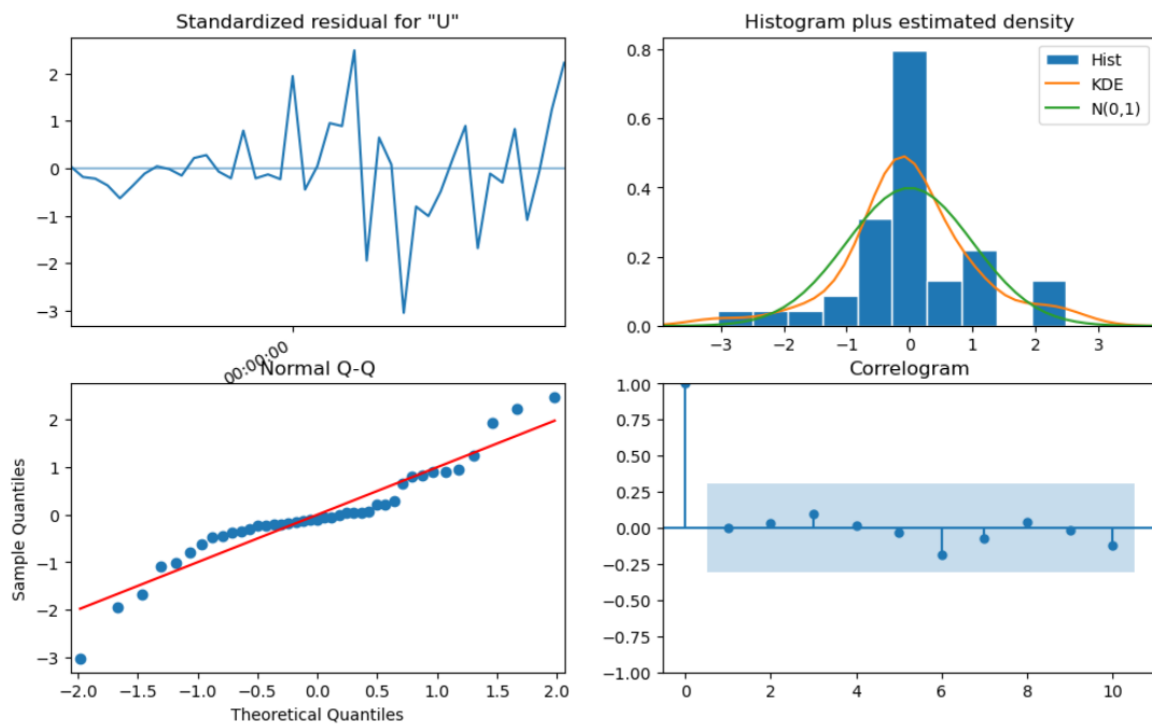


Рис. 60. Данные и проверка третьей модели ARIMA

К сожалению, некоторые модели, несмотря на отсутствие автокорреляции и достаточно хорошего распределения остатков, имели много незначимых переменных. Поэтому такие модели необходимо было улучшить.

Путем дополнительного подбора переменных удалось подобрать более удачные коэффициенты.

Модель 2 осталась неизменной.

Скорректированные параметры моделей ARIMA

Модель	Параметры	AIC
1	(2, 2, 1)	487.477
2	(1, 1, 1)	350.067
3	(0, 2, 0)	513.801
4	(2, 1, 1)	430.940

Таким образом, можно построить скорректированные модели ARIMA для рассматриваемых моделей.

```
In [27]: model1 = ARIMA(df1, order=(2, 2, 1))
result1 = model1.fit()
result1.summary()
```

Out[27]: SARIMAX Results

Dep. Variable:	Barl_Price		No. Observations:		43	
Model:	ARIMA(2, 2, 1)		Log Likelihood		-239.738	
Date:	Thu, 17 Nov 2022		AIC		487.477	
Time:	01:39:10		BIC		494.331	
Sample:	01-01-1970		HQIC		489.973	
	- 01-01-1970					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.3423	0.120	2.857	0.004	0.108	0.577
ar.L2	-0.3822	0.179	-2.140	0.032	-0.732	-0.032
ma.L1	-0.9569	0.182	-5.255	0.000	-1.314	-0.600
sigma2	6560.2473	1425.415	4.602	0.000	3766.485	9354.009
Ljung-Box (L1) (Q):	0.01	Jarque-Bera (JB):		0.77		
Prob(Q):	0.93	Prob(JB):		0.68		
Heteroskedasticity (H):	1.81	Skew:		0.34		
Prob(H) (two-sided):	0.28	Kurtosis:		3.02		

```
In [48]: result1.plot_diagnostics(figsize=(12, 8))
plt.show()
```

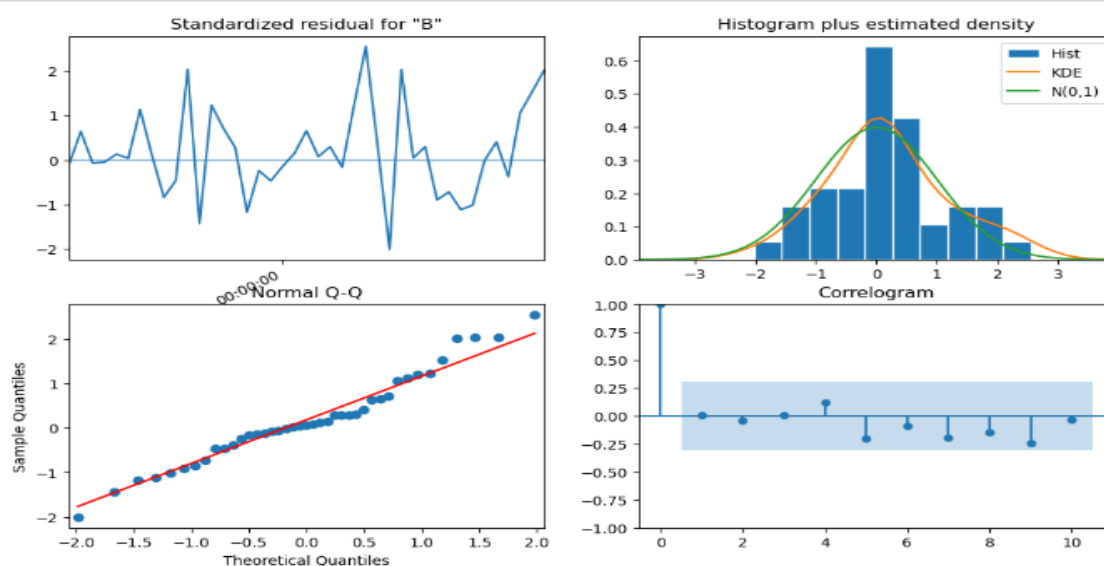


Рис. 61. Данные и проверка первой скорректированной модели ARIMA

```
In [38]: model2 = ARIMA(df2, order=(1, 1, 1))
result2 = model2.fit()
result2.summary()
```

Out[38]: SARIMAX Results

Dep. Variable:	Oil_price	No. Observations:	43			
Model:	ARIMA(1, 1, 1)	Log Likelihood	-172.033			
Date:	Thu, 17 Nov 2022	AIC	350.067			
Time:	01:40:01	BIC	355.280			
Sample:	01-01-1970	HQIC	351.978			
	- 01-01-1970					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
ar.L1	-0.5915	0.317	-1.868	0.062	-1.212	0.029
ma.L1	0.7443	0.276	2.692	0.007	0.202	1.286
sigma2	211.1045	31.156	6.776	0.000	150.040	272.169
Ljung-Box (L1) (Q):	0.28	Jarque-Bera (JB):	17.04			
Prob(Q):	0.60	Prob(JB):	0.00			
Heteroskedasticity (H):	23.25	Skew:	-0.68			
Prob(H) (two-sided):	0.00	Kurtosis:	5.81			

```
In [49]: result2.plot_diagnostics(figsize=(12, 8))
plt.show()
```

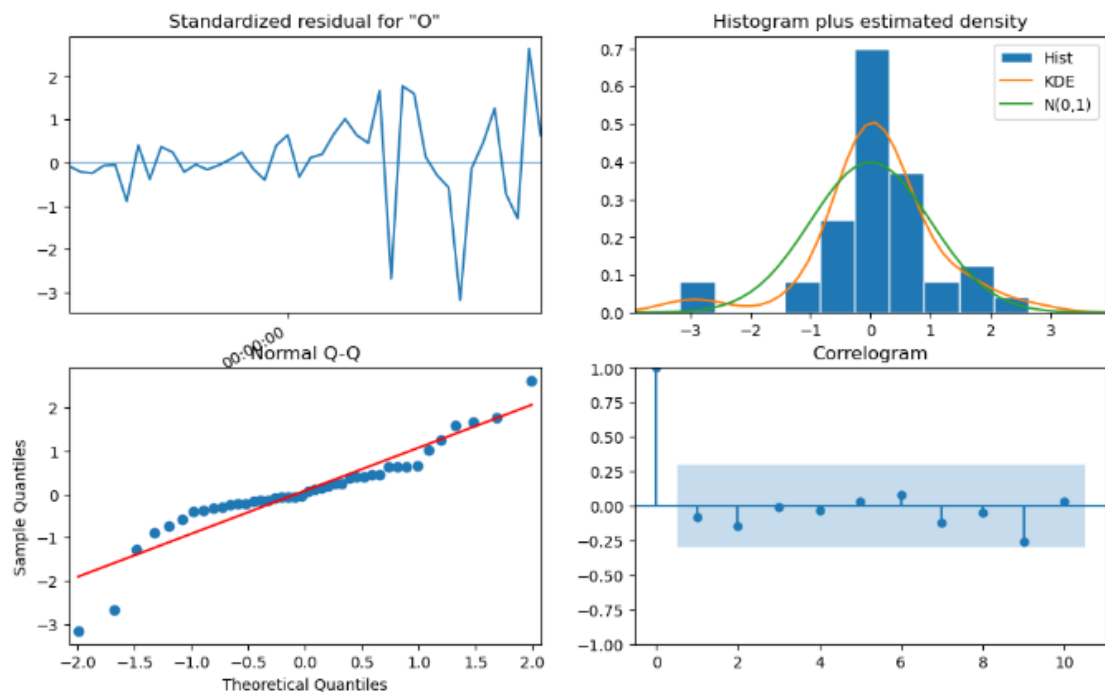


Рис. 62. Данные и проверка второй скорректированной модели ARIMA

```
In [47]: model4 = ARIMA(df4, order=(2, 1, 1))
result4 = model4.fit()
result4.summary()
```

Out[47]: SARIMAX Results

Dep. Variable:	US_gas_price	No. Observations:	43			
Model:	ARIMA(2, 1, 1)	Log Likelihood	-211.470			
Date:	Thu, 17 Nov 2022	AIC	430.940			
Time:	01:40:46	BIC	437.891			
Sample:	01-01-1970	HQIC	433.488			
	- 01-01-1970					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
ar.L1	-1.0234	0.139	-7.336	0.000	-1.297	-0.750
ar.L2	-0.4004	0.118	-3.400	0.001	-0.631	-0.170
ma.L1	0.9415	0.128	7.382	0.000	0.692	1.191
sigma2	1337.5932	252.020	5.307	0.000	843.644	1831.543
Ljung-Box (L1) (Q):	0.01	Jarque-Bera (JB):	4.91			
Prob(Q):	0.93	Prob(JB):	0.09			
Heteroskedasticity (H):	22.91	Skew:	0.06			
Prob(H) (two-sided):	0.00	Kurtosis:	4.67			

```
In [51]: result4.plot_diagnostics(figsize=(12, 8))
plt.show()
```

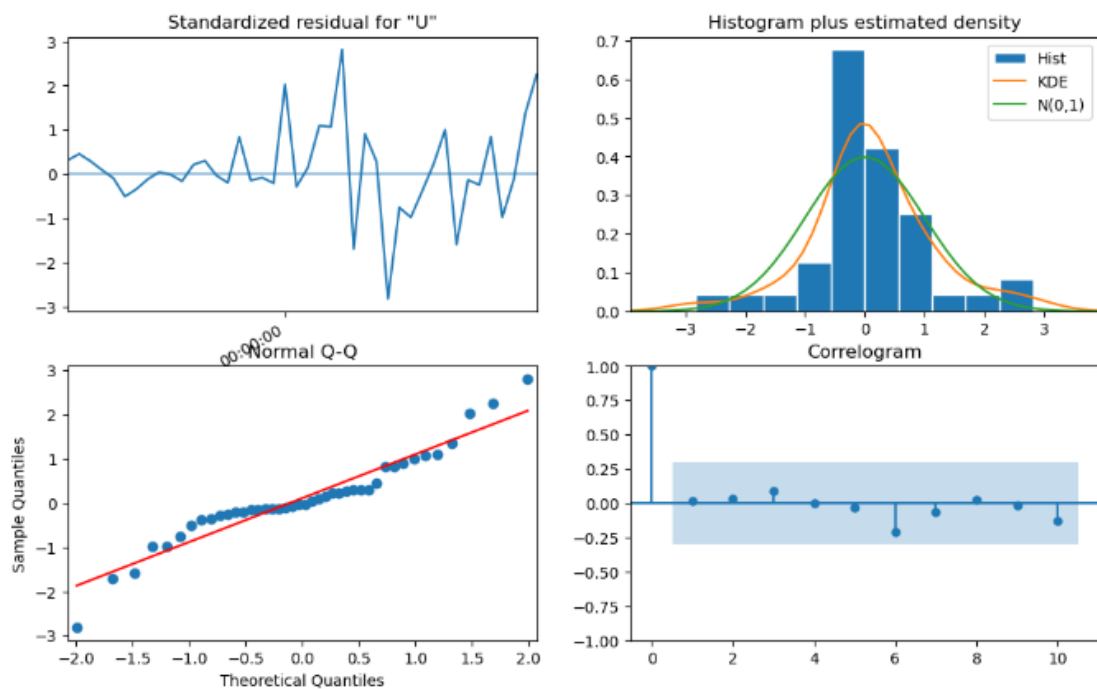


Рис. 63. Данные и проверка четвертой скорректированной модели ARIMA

Таким образом, были созданы простые модели прогнозирования модели ARIMA для анализа цен на основные биржевые товары. При хорошо подобранных параметрах модели имеют высокую точность, несмотря на небольшую автокорреляцию (что можно объяснить спецификой рассматриваемых параметров) и распределение остатков.

Таким образом, в рамках данной части проекта были построены линейные и нелинейные модели оценки влияния санкций на основные биржевые товары, а также дополнительные модели.

Такие модели позволят примерно спрогнозировать динамику цен на товары с учетом того, что информация о санкциях будет появляться в нынешней политической ситуации постоянно. Количество оценочных пакетов санкций в разных отраслях также позволит в краткосрочной перспективе оценить динамику всего рынка.

В последней части работы данные будут переведены в текстовый вид, уравнение регрессии будут представлены в более общем виде, а также будет сделан общий вывод в рамках данной работы.